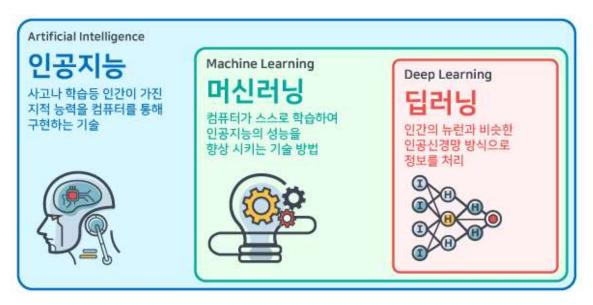




인공 지능 머신 러닝 딥 러닝

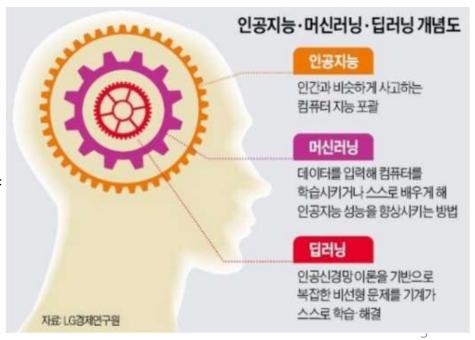
▶ 인공 지능

- 인공 지능 1956년 미국 다트머스 대학에 있던 존 매카시 교수가 개최한 다트머스 회의에서 처음 등장
- 2015년 이후 신속하고 강력한 병렬 처리 성능을 제공하는 GPU의 도입으로 인공지능의 성장세 가속화 폭발적으로 늘어나고 있는 저장 용량과 이미지, 텍스트, 매핑 데이터 등 모든 영역의 데이터가 범람하게 된 '빅데이터'가 인공지능의 성장세에 큰 영향을 줌
- 인간이 지닌 지적 능력을 인공적으로 구현한 것
- 기계 혹은 시스템에 의해 만들어진 지능General AI 인간의 감각, 사고력을 지닌 채 인간처럼 생각하는 인공 지능
- Narrow AI 소셜 미디어의 이미지 분류 서비스나 얼굴 인식 기능 등과 같이 특정 작업을 인간 이상의 능력으로 해낼 수 있는 것
- 인간의 학습능력, 추론능력, 지각능력, 자연언어 등의 이해능력을 컴퓨터 프로그래밍으로 구현한 기술



▶ 머신 러닝

- 알고리즘을 이용해 데이터를 분석하고, 분석을 통해 학습하며, 학습한 내용을 기반으로 판단이나 예측을 합니다.
- 궁극적으로는 의사 결정 기준에 대한 구체적인 지침을 소프트웨어에 직접 코딩해 넣는 것이 아닌, 대량의 데이터와 알고리즘을 통해 컴퓨터 그 자체를 '학습'시켜 작업 수행 방법을 익히는 것을 목표로 함
- 알고리즘 방식 의사 결정 트리 학습, 귀납 논리 프로그래밍, 클러스터링, 강화 학습, 베이지안(Bayesian) 네트워크 등이 포함
- 공지능의 한 분야로서 빅데이터를 분석하고 가공해서 새로운 정보를 얻어 내거나 미래를 예측하는 기술
- 인공지능의 하위 분야
- 기계가 직접 데이터를 학습(러닝)함으로써 그 속에 숨겨진 일련의 규칙성을 찾는다
- 예] 문자인식, 음성인식, 바둑 또는 장기 등의 게임 전략 , 의료 진단, 로봇개발

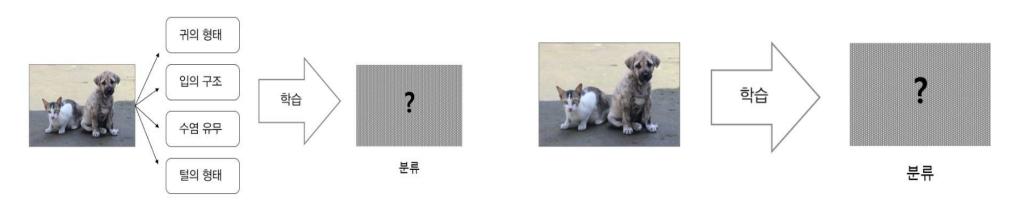


▶ 머신 러닝 응용분야

- 클래스 분류(Classification)
- 클러스터링 그룹 나누기(Clustering)
- 추천(Recommendation)
- 회귀(Regression)
- 차원 축소(Dimensionality Reduction) 특성을 유지한 상태로 고차원의 데이터를 저차원의 데이터로 변환하는 것
- 데이터를 시각화하거나 구조를 추출해서 용량을 줄여 계산을 빠르게 하거나 메모리를 절약할때 사용
- 초과 적합(Overfitting) 훈련 전용 데이터가 학습돼 있지만 학습되지 않은 새로운 데이터에 대해 제대로 된 예측을 못하는 상태

▶ 딥러닝(심층학습, 강화학습)

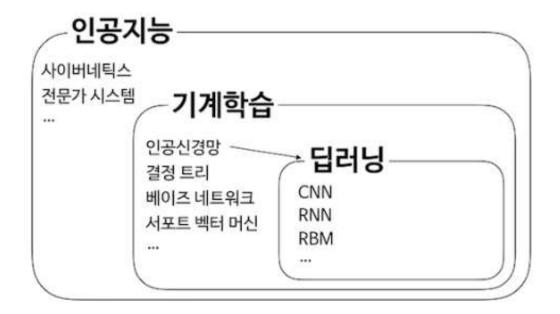
- 여러 층을 가진 인공신경망을 이용하여 머신러닝을 수행하는 것
- 인공신경망을 넓고 다층(Deep)으로 쌓으면 딥러닝(Deep-Learning) 🣃
- 신경망을 사용해 수많은 데이터 속에서 어떤 패턴을 파악하고 이것을 통해 인간이 사물을 구분하듯이 컴퓨터가 데이터를 나누는 것 (사물이나 데이터를 군집화 하거나 분류할 때 사용)
- 데이터 자체를 컴퓨터에게 전달, 인공신경망 구조를 사용하여 데이터 전체를 학습시킨다 (인간의 뇌에서 일어나는 의 사결정 과정을 모방한 인공신경망(Artificial Neural Network) 구조를 통해서 학습한다)
- 예] 컴퓨터에 개와 고양이 사진을 학습시켜 특정사진의 동물이 개인지 고양이인지 분류 (일반적인 기계학습의 경우 개와 고양이의 구별되는 큰 특징들만 뽑아 컴퓨터에게 전달) 딥러닝은 개, 고양이 사진 자체를 컴퓨터가 학습하도록 하는 것

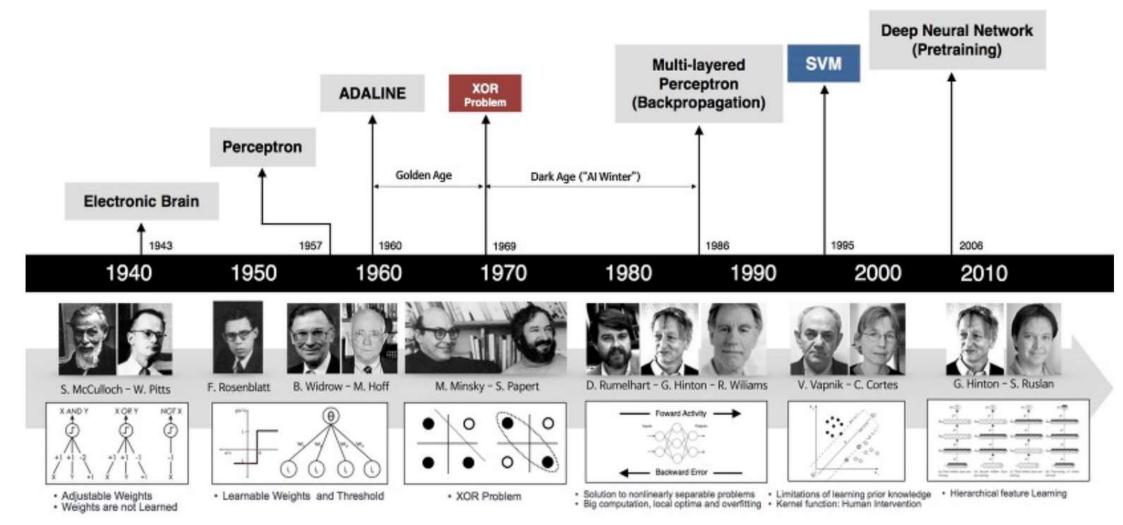


딥러닝을 통한 개와 고양이 분류

5

- ▶ 인공 지능과 머신 러닝, 딥 러닝의 차이점
 - 딥러닝 단계에서 군집화된 데이터를 분류 → 머신러닝 단계를 거쳐 학습 → 인공지능의 단계에서는 어떤 판단이나 결과를 내는 과정



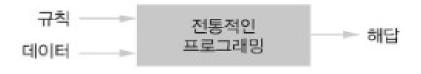


▶ 인공 신경망

- 인공 신경망(딥러닝)이 2012년 ILSVRC2012대회헤서 깊게 쌓은 딥러닝 모델 AlexNet이 우승하면서 다시 주목받게 된 계기
- 빅데이터 시대인 요듬 신경망을 학습시키기 위한 데이터가 엄청나게 많아 졌다
- 신경망은 다른 머신러닝 알고리즘보다 규모가 크고 복잡한 문제에서 성능이 좋다
- 1990년대 이후 크게 발전된 컴퓨터 하드웨어 성능과 Matrix연산에 고성능인 GPU로 인해 상대적으로 짧은 시간 안에 대규모의 신경망을 학습시킬 수 있게 되었다.
- 최초의 인공 뉴런 하나 이상의 이진(on/off)입력과 하나 이상의 출력을 가진다.

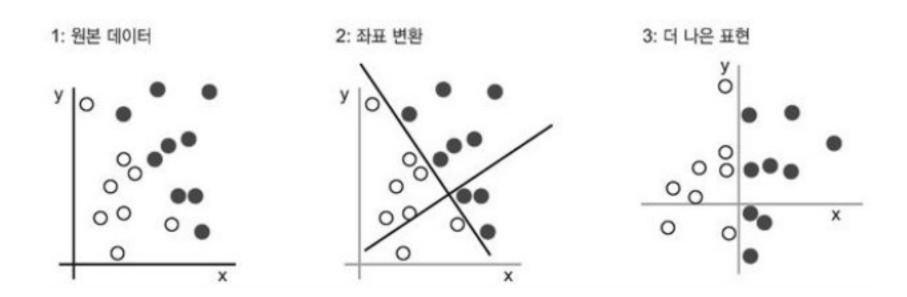
> AI의 패러다임

- 심볼릭 AI의 패러다임 규칙(프로그램)과 이 규칙에 따라 처리될 데이터를 입력하면 해답이 출력
- 머신 러닝 데이터와 데이터로부터 기대되는 해답을 입력하면 규칙이 출력
- 머신러닝은 데이터에서 통계적 구조를 찾아 그 작업을 자동화하기 위한 규칙을 만들어 냅니다. (<mark>학습</mark>)
- 머신 러닝 모델은 입력 데이터를 기반으로 기대 출력에 가깝게 만드는 유용한 표현(representation)을 학습하는 것
- 머신 러닝에서의 학습(Learning)이란 더 나은 표현을 찾는 자동화된 과정입니다.
- 모든 머신 러닝 알고리즘은 주어진 작업을 위해 데이터를 더 유용한 표현으로 바꾸는 이런 변환을 자동으로 찾습니다.
- 머신 러닝 연산 선형 투영(linear projection)(정보를 잃을 수 있음), 이동(translation), 비선형 연산(예를 들어 x > 0인 모든 포인트를 선택하는 것) 등
- 가설 공간(hypothesis space)이라 부르는 미리 정의된 연산의 모음들을 자세히 조사하는 것
- 머신 러닝은 가능성 있는 공간을 사전에 정의하고 피드백 신호의 도움을 받아 입력 데이터에 대한 유용한 변환을 찾는 것





- 흰색 포인트와 검은색 포인트의 좌표 (x, y)를 입력으로 받고, 포인트가 검은색인지 흰색인지를 출력하는 알고리즘을 개발
 - 입력은 포인트의 좌표
 - 기대 출력은 포인트의 색깔
 - 알고리즘의 성능을 측정하는 방법은 정확히 분류한 포인트의 비율을 사용하여 알고리즘의 성능을 측정



▶ 딥러닝

- 기본 층을 겹겹이 쌓아 올려 구성한 신경망(neural network)이라는 모델을 사용하여 표현 층을 학습
- 층 기반 표현 학습(layered representations learning) 또는 계층적 표현 학습(hierarchical representations learning)
- ➢ 깊은 신경망(Deep Neural Network : DNN)
 - 신경망을 3개 이상 중첩

환경설정 및 라이브러리

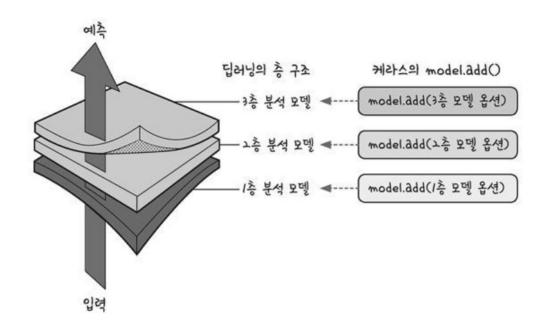
> 딥러닝 라이브러리

- 케라스(keras)를 사용해 딥러닝을 실행시킵니다.
- 케라스가 구동되려면 텐서플로(TensorFlow) 또는 씨아노(theano)라는 두 가지 라이브러리 중 하나가 미리 설치되어 있어야 합니다

from keras.models import Sequential from keras.layers import Dense

환경설정 및 라이브러리

- keras 라이브러리 Sequential() 와 Dense()
 - Sequential() 딥러닝의 구조를 한 층 한 층 쉽게 쌓아올릴 수 있게 해 줍니다.
 - Sequential 함수를 선언하고 나서 model.add() 함수를 사용해 필요한 층을 차례로 추가합니다.
 - Dense(activation=, loss=, optimizer=) 각 층이 제각각 어떤 특성을 가질지 옵션을 설정하는 역할을 합니다.
 - activation: 다음 층으로 어떻게 값을 넘길지 결정하는 부분(가장 많이 사용되는 relu와 sigmoid 함수)
 - loss: 한 번 신경망이 실행될 때마다 오차 값을 추적하는 함수
 - optimizer: 오차를 어떻게 줄여 나갈지 정하는 함수
 - model.evaluate() 딥러닝의 모델이 어느 정도 정확하게 예측하는지를 점검



- 구글이 공개한 대규모 숫자 계산을 해주는 머신러닝 및 딥러닝 전문 라이브러리
- Tensor는 다차원 행렬 계산을 의미
- 상업적인 용도로 사용할 수 있는 오픈소스(Apache 2.0)
- C++로 만들어진 라이브러리
- 파이썬을 사용해서 호출할 때 오버헤드가 거의 없는 구조로 설계
- https://www.tensorflow.org
- 이미지 처리와 음향 처리 등을 할 때는 추가적으로 이미지 처리에 특화된 OpenCV 라이브러리등과 함께 사용

> TensorFlow

```
import tensorflow as tf
print(tf.__version__)
```

```
import tensorflow as tf

#상수 정의
a = tf.constant(1234)
b = tf.constant(5000)

#계산 정의
add_op = a+b

#세션 시작
sess = tf.Session()
res = sess.run(add_op) #계산식 평가
print(res)
```

pip uninstall tensorflow pip install tensorflow==1.15

```
import tensorflow as tf
#상수 정의
a = tf.constant(2)
b = tf.constant(3)
c = tf.constant(4)
#계산 정의
calc1 op = a + b *c
calc2 op = (a+b) * c
#세션 시작
sess = tf.Session()
res1 = sess.run(calc1_op) #계산식 평가
print(res1)
res2 = sess.run(calc2 op) #계산식 평가
print(res2)
```

```
import tensorflow as tf
#상수 정의
a = tf.constant(100)
b = tf.constant(50)
add op = a + b
#변수 v 선언하기
v = tf.Variable(0)
# 변수 v에 add_op의 결과 대입하기
let_op = tf.assign(v, add_op)
#세션 시작
sess = tf.Session()
# 변수 초기화히기 (메모리에 생성)
sess.run(tf.global_variables_initializer())
#계산식 실행
sess.run(let_op)
print(sess.run(v))
```

- placeholder 템플릿처럼 값을 넣을 공간을 만들어두는 기능
- 데이터 플로우 그래프를 구축할 때는 값을 넣지 않고 값을 담을 수 있는 그릇만 만들어두고, 이후에 세션을 실행할 때 그릇에 값을 넣고 실행할 수 있습니다

```
import tensorflow as tf

#placeholder 정의(정수 자료형 3개를 가진 배열)
a = tf.placeholder(tf.int32, [3])
b = tf.constant(2)
x2_op = a* b

#세션 시작
sess = tf.Session()
# placeholder에 값 넣고 실행하기
r1 = sess.run(x2_op, feed_dict = {a:[1, 2, 3]})
print(r1)
r2 = sess.run(x2_op, feed_dict = {a:[10, 20, 10]})
print(r2)
```

- tensoflow.sqrt(x): x의 제곱근을 계산
- tensoflow.reduce_mean(x): x의 평균을 계산
- tensoflow.square(x): x의 제곱을 계산
- random_uniform([1], 0, 10,...): 0에서 10 사이에서 임의의 수 1개 생성 반환
- Variable() : 변수의 값을 지정

- placeholder 템플릿처럼 값을 넣을 공간을 만들어두는 기능
- 데이터 플로우 그래프를 구축할 때는 값을 넣지 않고 값을 담을 수 있는 그릇만 만들어두고, 이후에 세션을 실행할 때 그릇에 값을 넣고 실행할 수 있습니다

```
import tensorflow as tf

#placeholder 정의(정수 자료형 3개를 가진 배열)
a = tf.placeholder(tf.int32, [3])
b = tf.constant(2)
x2_op = a* b

#세션 시작
sess = tf.Session()
# placeholder에 값 넣고 실행하기
r1 = sess.run(x2_op, feed_dict = {a:[1, 2, 3]})
print(r1)
r2 = sess.run(x2_op, feed_dict = {a:[10, 20, 10]})
print(r2)
```

```
import tensorflow as tf

#placeholder 정의(배열의 크기를 None으로 지정)
a = tf.placeholder(tf.int32, [None])
b = tf.constant(10)
x10_op = a* b

#세션 시작
sess = tf.Session()
# placeholder에 값 넣고 실행하기
r1 = sess.run(x10_op, feed_dict = {a:[1, 2, 3, 4, 5]})
print(r1)
r2 = sess.run(x10_op, feed_dict = {a:[10, 20]})
print(r2)
```

- SVM으로 BMI 판정
- 키의 최대값은 200cm, 몸무게의 최대값은 100kg으로 정규화
- 저체중(thin), 정상(normal), 비만(fat) 레이블을 one-hot-encoding [1, 0, 0], [0, 1, 0], [0, 0, 1]로 변환
- 소프트 맥스 회귀방법 , 오차 함수는 교차 엔트로피 사용
- 교차 엔트로피 2개의 확률 분포 사이에 정의되는 척도로서 교차 엔트로피 값이 작을 수록 정확한 값을 냄
- 학습 계수 0.01, 경사 하강법(steepest descent method) 사용

```
import pandas as pd import numpy as np import tensorflow as tf # 키, 몸무게, 레이블이 적힌 CSV 파일 읽어 들이기 csv = pd.read_csv("bmi.csv") # 데이터 정규화 csv["height"] / 200 csv["weight"] = csv["weight"] / 100 # 레이블을 배열로 변환하기 - thin=(1,0,0) / normal=(0,1,0) / fat=(0,0,1) bclass = {"thin": [1,0,0], "normal": [0,1,0], "fat": [0,0,1]} csv["label_pat"] = csv["label"].apply(lambda x : np.array(bclass[x])) # 테스트를 위한 데이터 분류 test_csv = csv[15000:20000] test_pat = test_csv["weight","height"]] test_ans = list(test_csv["label_pat"])
```

```
# 데이터 플로우 그래프 구축하기
# 플레이스홀더 선언하기
x = tf.placeholder(tf.float32, [None, 2]) # 키와 몸무게 데이터 넣기
y_ = tf.placeholder(tf.float32, [None, 3]) # 정답 레이블 넣기
# 변수 선언하기
W = tf.Variable(tf.zeros([2, 3])); # 가중치
b = tf.Variable(tf.zeros([3])); # 바이어스
# 소프트맥스 회귀 정의하기
y = tf.nn.softmax(tf.matmul(x, W) + b)
# 모델 훈련하기
cross_entropy = -tf.reduce_sum(y_ * tf.log(y))
optimizer = tf.train.GradientDescentOptimizer(0.01)
train = optimizer.minimize(cross entropy)
# 정답률 구하기
predict = tf.equal(tf.argmax(y, 1), tf.argmax(y_,1))
accuracy = tf.reduce mean(tf.cast(predict, tf.float32))
# 세션 시작하기
sess = tf.Session()
sess.run(tf.global variables initializer()) # 변수 초기화하기
```

```
# 학습시키기
for step in range(3500):
    i = (step * 100) % 14000
    rows = csv[1 + i : 1 + i + 100]
    x_pat = rows[["weight","height"]]
    y_ans = list(rows["label_pat"])
    fd = {x: x_pat, y_: y_ans}
    sess.run(train, feed_dict=fd)
    if step % 500 == 0:
        cre = sess.run(cross_entropy, feed_dict=fd)
        acc = sess.run(accuracy, feed_dict={x: test_pat, y_: test_ans})
        print("step=", step, "cre=", cre, "acc=", acc)
# 최종적인 정답률 구하기
acc = sess.run(accuracy, feed_dict={x: test_pat, y_: test_ans})
    print("정답률 =", acc)
```

TensorBoard

- 데이터의 흐름을 시각화하는 도구
- 로그 데이터를 저장할 폴더 준비
- tensorbord –logdir=로그데이터 저장폴더
- ocalhost:6006

```
import tensorflow as tf
# 데이터 플로우 그래프 구축하기
a = tf.constant(20, name="a")
b = tf.constant(30, name="b")
mul_op = a * b
# 세션 생성하기
sess = tf.Session()
# TensorBoard 사용하기
tw = tf.summary.FileWriter("log_dir", graph=sess.graph)
# 세션 실행하기
print(sess.run(mul_op))
```

> TensorBoard

```
import tensorflow as tf
# 상수와 변수 선언하기
a = tf.constant(100, name="a")
b = tf.constant(200, name="b")
c = tf.constant(300, name="c")
v = tf.Variable(0, name="v")
# 곱셈을 수행하는 그래프 정의하기
calc op = a + b * c
assign_op = tf.assign(v, calc_op)
# 세션 생성하기
sess = tf.Session()
# TensorBoard 사용하기
tw = tf.summary.FileWriter("log_dir", graph=sess.graph)
# 세션 실행하기
sess.run(assign_op)
print(sess.run(v))
```

▶ TensorBoard – BMI 판정

```
import pandas as pd
import numpy as np
import tensorflow as tf
# 키, 몸무게, 레이블이 적힌 CSV 파일 읽어 들이기
csv = pd.read csv("bmi.csv")
# 데이터 정규화
csv["height"] = csv["height"] / 200
csv["weight"] = csv["weight"] / 100
# 레이블을 배열로 변환하기
# - thin=(1,0,0) / normal=(0,1,0) / fat=(0,0,1)
bclass = {"thin": [1,0,0], "normal": [0,1,0], "fat": [0,0,1]}
csv["label_pat"] = csv["label"].apply(lambda x : np.array(bclass[x]))
# 테스트를 위한 데이터 분류
test csv = csv[15000:20000]
test_pat = test_csv[["weight","height"]]
test ans = list(test csv["label pat"])
# 플레이스홀더로 이름 붙이기
x = tf.placeholder(tf.float32, [None, 2], name="x")
y_ = tf.placeholder(tf.float32, [None, 3], name="y_")
```

➤ TensorBoard – BMI 판정

```
# interface 부분을 스코프로 묶기
with tf.name_scope('interface') as scope:
  W = tf.Variable(tf.zeros([2, 3]), name="W"); # 가중치
   b = tf.Variable(tf.zeros([3]), name="b"); # 바이어스
  # 소프트맥스 회귀 정의 --- (※7)
  with tf.name scope('softmax') as scope:
     y = tf.nn.softmax(tf.matmul(x, W) + b)
# loss 계산을 스코프로 묶기
with tf.name scope('loss') as scope:
   cross_entropy = -tf.reduce_sum(y_ * tf.log(y))
# training 계산을 스코프로 묶기
with tf.name scope('training') as scope:
   optimizer = tf.train.GradientDescentOptimizer(0.01)
  train = optimizer.minimize(cross entropy)
# accuracy 계산을 스코프로 묶기
with tf.name scope('accuracy') as scope:
   predict = tf.equal(tf.argmax(y, 1), tf.argmax(y_,1))
   accuracy = tf.reduce mean(tf.cast(predict, tf.float32))
```

> TensorBoard - BMI 판정

```
# 세션 시작하기
with tf.Session() as sess:
   tw = tf.train.SummaryWriter("log_dir", graph=sess.graph)
   sess.run(tf.initialize all variables()) # 변수 초기화하기
   # 테스트 데이터를 이용해 학습하기
  for step in range(3500):
     i = (step * 100) \% 14000
      rows = csv[1 + i : 1 + i + 100]
      x pat = rows[["weight","height"]]
     y_ans = list(rows["label_pat"])
     fd = \{x: x_pat, y_: y_ans\}
      sess.run(train, feed dict=fd)
      if step \% 500 == 0:
         cre = sess.run(cross entropy, feed dict=fd)
         acc = sess.run(accuracy, feed_dict={x: test_pat, y_: test_ans})
         print("step=", step, "cre=", cre, "acc=", acc)
   # 최종적인 정답률 구하기
   acc = sess.run(accuracy, feed_dict={x: test_pat, y_: test_ans})
   print("정답률=", acc)
```

> Keras

- 머신러닝 라이브러리 Theano와 TensorFlow를 래핑한 라이브러리
- https://keras.io/
- Sequential로 딥러닝의 각 층을 add()로 추가
- 활성화 함수, Dropout 등 add()로 간단하게 추가
- compile()로 모델 구축
- loss 로 최적화 함수 지정
- fit() 로 모델에 데이터를 학습시킴
- Keras로 머신러닝을 수행할 때 Numpy 배열 데이터를 전달해야 한다

➤ Keras이용 BMI 판정

```
from keras.models import Sequential
from keras.layers.core import Dense, Dropout, Activation
from keras.callbacks import EarlyStopping
import pandas as pd, numpy as np
# BMI 데이터를 읽어 들이고 정규화하기
csv = pd.read csv("bmi.csv")
# 몸무게와 키 데이터
csv["weight"] /= 100
csv["height"] /= 200
X = csv[["weight", "height"]].as matrix()
#레이블
bclass = {"thin":[1,0,0], "normal":[0,1,0], "fat":[0,0,1]}
y = np.empty((20000,3))
for i, v in enumerate(csv["label"]):
  v[i] = bclass[v]
# 훈련 전용 데이터와 테스트 전용 데이터로 나누기
X \text{ train, } y \text{ train} = X[1:15001], y[1:15001]
X_{\text{test}}, y_{\text{test}} = X[15001:20001], y[15001:20001]
# 모델 구조 정의하기
model = Sequential()
model.add(Dense(512, input_shape=(2,)))
model.add <u>tivation('relu')</u>
```

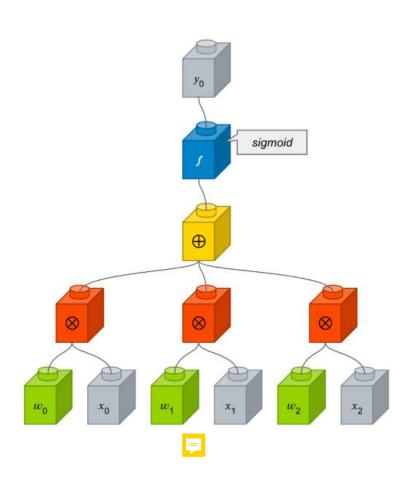
➤ Keras이용 BMI 판정

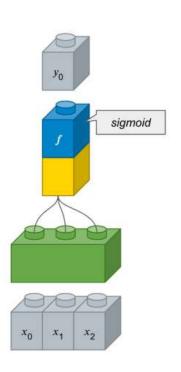
```
model.add(Dropout(0.1))
model.add(Dense(512))
model.add(Activation('relu'))
model.add(Dropout(0.1))
model.add(Dense(3))
model.add(Activation('softmax'))
# 모델 구축하기
model.compile( loss='categorical crossentropy',
                                                optimizer="rmsprop",
                                                                        metrics=['accuracy'])
# 데이터 훈련하기
hist = model.fit(
  X train, y train,
  batch size=100,
  nb epoch=20,
  validation_split=0.1,
  callbacks=[EarlyStopping(monitor='val loss', patience=2)]
  verbose=1)
# 테스트 데이터로 평가하기
score = model.evaluate(X_test, y_test)
print('loss=', score[0])
print('accuracy=', score[1])
```

Keras이용 BMI 판정

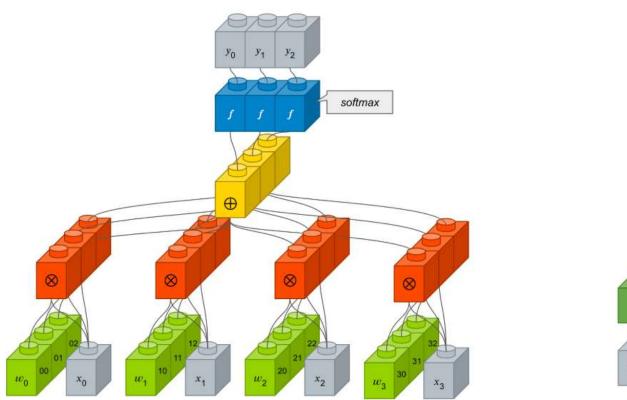
- weight decay(가중치 감소) 학습중 가중치가 큰 것에 대해서 패널티를 부과해 과적합의 위험을 줄이는 방법
- Dropout 복잡한 신경망에서 가중치 감소만으로 과적합을 피하기 어려운 경우 뉴런의 연결을 임의로 삭제시켜 신호를 전달하지 못하도록 하는 방법
- softmax 회귀 입력받은 값을 출력으로 0~1사이의 값으로 모두 정규화하여 출력값들의 총합은 항상 1이 되는 특성의 함수
- 분류하고 싶은 클래스 수 만큼 출력으로 구성
- 소프트 맥스 결과값을 One hot encoder의 입력으로 연결하면 가장 큰 값만 True값, 나머지는 False 값이 나오게 하여 이용 가능하다
- val loss는 에포크 힛수가 많아질 수록 감소하다가 다시 증가됨을 보이는 경우, 과적합이 발생한 것입니다.
- 학습에 더 이상 개선의 여지가 없을 경우 학습을 종료시키는 콜백함수(수행중인 함수에서 지정된 함수를 호출,되부름) 는 EarlyStopping 입니다.
- Dense(출력 뉴런의 수, input_dim=입력 뉴런의 수, init= 가중치 초기화 방법, activation=활성화 함수)
- relu 활성화 함수는 은닉층에 주로 사용
- sigmoid 활성화 함수는 이진 분류 문제에서 출력층에 주로 사용
- softmax 활성화 함수는 다중 클래스 분류 문제에서 출력층에 주로 사용

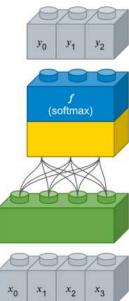
Dense(1, input_dim=3, activation='sigmoid'))



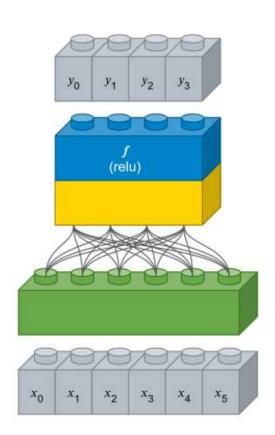


Dense(3, input_dim=4, activation='softmax')





Dense(4, input_dim=6, activation='relu'))





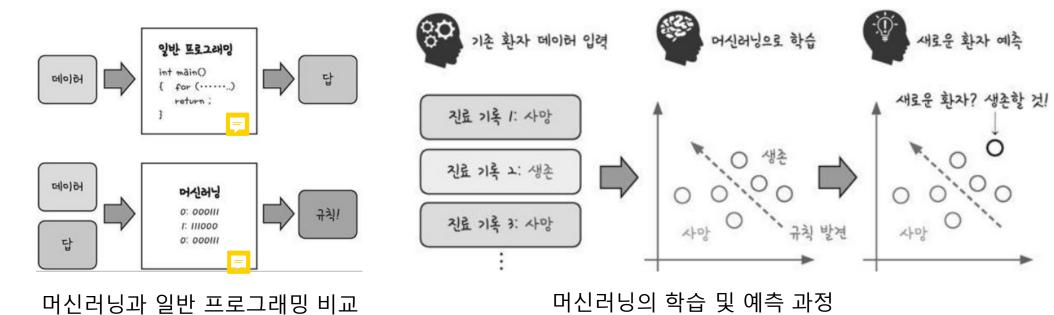


딥러닝 동작원리

Deep Learning

▶ 머신러닝

- 데이터 안에서 규칙을 발견하고 그 규칙을 새로운 데이터에 적용해서 새로운 결과를 도출
- 기존 데이터를 이용해 아직 일어나지 않은 미지의 일을 예측하기 위해 만들어진 기법



36

SQL Tuning Process

▶ 폐암 수술 환자의 생존율 예측하기

```
# 실행할 때마다 같은 결과를 출력하기 위해 설정하는 부분입니다.
seed = 0
numpy.random.seed(seed)
tf.set random seed(seed)
# 준비된 수술 환자 데이터를 불러들입니다.
Data_set = numpy.loadtxt("../dataset/ThoraricSurgery.csv", delimiter=",")
# 환자의 기록과 수술 결과를 X와 Y로 구분하여 저장합니다.
X = Data set[:,0:17]
Y = Data set[:,17]
# 딥러닝 구조를 결정합니다(모델을 설정하고 실행하는 부분입니다).
model = Sequential()
model.add(Dense(30, input dim=17, activation='relu'))
model.add(Dense(fractivation='sigmoid'))
# 딥러닝을 실행합니다.
model.compile(loss='mean_squared_error', optimizer='adam', metrics=['accuracy'])
model.fit(X, Y, epochs=30_batch size=10)
```

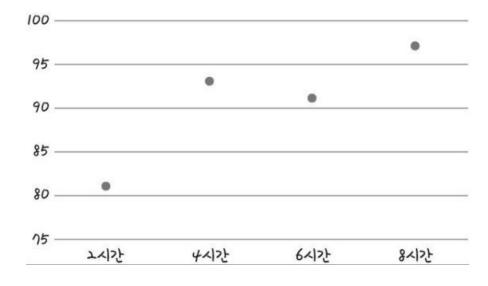
➤ 선형 회귀(linear regression)

- 단순 선형 회귀(simple linear regression) 하나의 x 값만으로 y 값을 설명
- 다중 선형 회귀(multiple linear regression) 여러개의 x 값이 y 값을 설명

공부한 시간	2시간	4시간	6시간	8시간
성적	81점	93점	91점	97점

$$x = \{2, 4, 6, 8\}$$

 $y = \{81, 93, 91, 97\}$



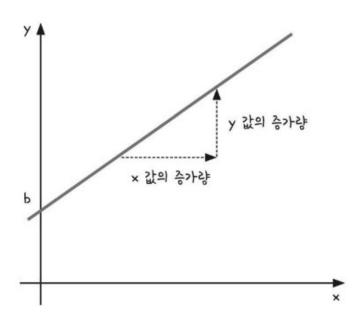
선형(직선으로 표시될 만한 형태)은 일차 함수 그래프로 표현됩니다.

$$y = ax + b$$

➤ 선형 회귀(linear regression)

■ 선형 회귀는 정확한 직선을 그려내는 과정으로 직선의 기울기 a 값과 y 절편 b 값을 정확히 예측해 내야 하는 것

a는 직선의 기울기, 즉 $\frac{y$ 값의 증가량 이고, b는 y축을 지나는 값인 'y 절편' x값의 증가량



최소 제곱법(method of least squares)

- 최소 제곱법 회귀 분석에서 사용되는 표준 방식
- 실험이나 관찰을 통해 얻은 데이터를 분석하여 미지의 상수를 구할 때 사용되는 공식
- 최소 제곱법을 통해 일차 함수의 기울기 a와 y 절편 b를 구할 수 있습니다.

$$a = \frac{\sum_{i=1}^{n} (x - mean(x)) (y - mean(y))}{\sum_{i=1}^{n} (x - mean(x))^{2}} \qquad a = \frac{(x - x \, \forall x) (y - y \, \forall x) \, d}{(x - x \, \forall x)^{2} \, d}$$

x의 편차(각 값과 평균과의 차이)를 제곱해서 합한 값을 분모로 놓고, x와 y의 편차를 곱해서 합한 값을 분자로 놓으면 기울기가 나옵니다.

- 공부한 시간(x) 평균: (2 + 4 + 6 + 8) ÷ 4 = 5
- 성적(y) 평균: (81+ 93 + 91 + 97) ÷ 4 = 90.5

$$a = \frac{(2-5)(81-90.5)+(4-5)(93-90.5)+(6-5)(91-90.5)+(8-5)(97-90.5)}{(2-5)^2+(4-5)^2+(6-5)^2+(8-5)^2}$$
$$= \frac{46}{20}$$
$$= 2.3$$

최소 제곱법(method of least squares)

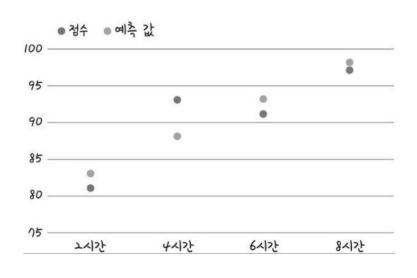
y 절편인 b를 구하는 공식 : b = mean(y) - (mean(x) * a)

b = y의 평균 - (x의 평균 × 기울기 a) b = 90.5 - (2.3 × 5) = 79

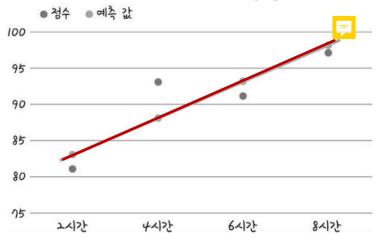
직선의 방정식: y = 2.3x + 79

최소 제곱법 공식으로 구한 성적 예측 값

공부한 시간	2	4	6	8
성적	81	93	91	97
예측 값	83.6	88.2	92.8	97.4



공부량에 따른 성적을 예측



▶ 최소 제곱법 공식으로 구한 성적 예측 코딩

```
import numpy as np
# x 값과 y 값
x=[2, 4, 6, 8]
y=[81, 93, 91, 97]
# x와 y의 평균값
mx = np.mean(x)
my = np.mean(y)
print("x의 평균값:", mx)
print("y의 평균값:", my)
# 기울기 공식의 분모
divisor = sum([(mx - i)**2 for i in x])
# 기울기 공식의 분자
def top(x, mx, y, my):
  d = 0
  for i in range(len(x)):
     d += (x[i] - mx) * (y[i] - my)
   return d
```

```
dividend = top(x, mx, y, my)

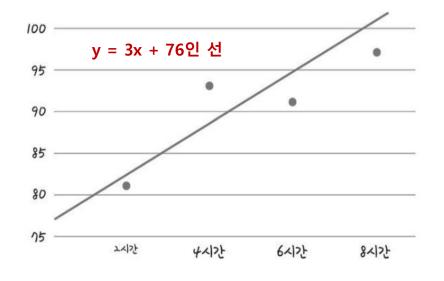
print("분모:", divisor)
print("분자:", dividend)

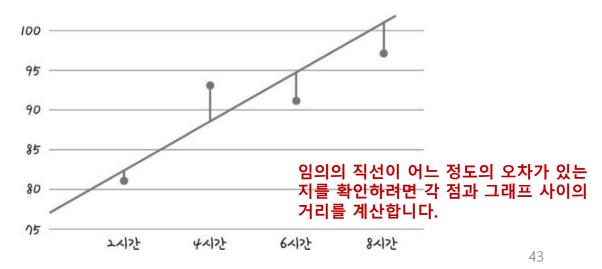
# 기울기와 y 절편 구하기
a = dividend / divisor
b = my - (mx*a)

# 출력으로 확인
print("기울기 a =", a)
print("y 절편 b =", b)
```

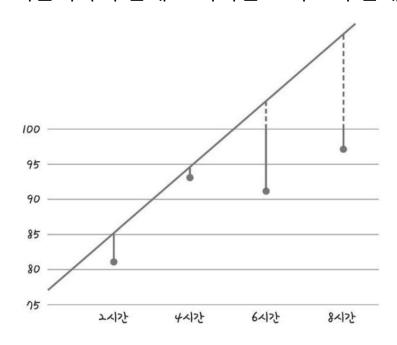
평균 제곱근 오차(root mean square error)

- 딥러닝은 대부분 입력 값이 여러 개인 상황에서 이를 해결하기 위해 실행됩니다.
- 여러 개의 입력 값을 계산할 때는 임의의 선을 그리고 난 후, 이 선이 얼마나 잘 그려졌는지를 평가하여
 조금씩 수정해 가는 방법을 사용합니다.
- 가설을 하나 세운 뒤 이 값이 주어진 요건을 충족하는지 판단하여 조금씩 변화를 주고, 이 변화가 긍정적 이면 오차가 최소가 될 때까지 이 과정을 계속 반복하는 방법입니다.
- 선을 긋고 나서 수정하는 과정에서 나중에 그린 선이 먼저 그린 선보다 더 좋은지 나쁜지를 판단하는 방법이 필요합니다.
- 각 선의 오차를 계산할 수 있어야 하고, 오차가 작은 쪽으로 바꾸는 알고리즘이 필요합니다.

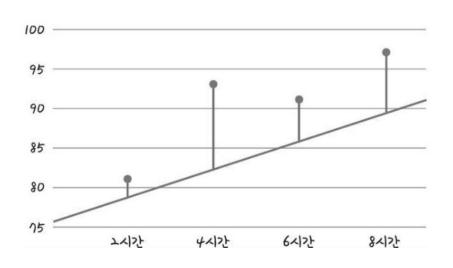




- ➤ 평균 제곱근 오차(root mean square error)
 - 기울기가 잘못되었을 수록 직선과의 거리의 합, 즉 오차의 합도 커집니다.
 - 기울기가 무한대로 커지면 오차도 무한대로 커지는 상관관계가 있습니다.



기울기를 너무 크게 잡았을 때의 오차



기울기를 너무 작게 잡았을 때의 오차

➤ 평균 제곱근 오차(root mean square error)

- 오차 = 실제 값 예측 값
- 오차의 합을 구할 때, 오차에 양수와 음수가 섞여 있기 때문에 오차를 단순히 더해 버리면 합이 0이 될 수도 있으므로 각 오차의 값을 제곱해 줍니다
- 평균 제곱 오차(Mean Squared Error, MSE) 오차 합의 평균
- 평균 제곱근 오차(Root Mean Squared Error, RMSE) 평균 제곱 오차는 각 오차를 제곱한 값을 사용하므로 대용량 데이터를 이용할 때는 오차가 커지고, 계산 속도가 느려지는 경우 제곱근을 씌워 줍니다.

공부한 시간(x)	2	4	6	8
성적(실제 값, y)	81	93	91	97
예측 값	82	88	94	100
오차	1	-5	3	3

오차의 합
$$=\sum_{i=1}^n \left(p_i-y_i\right)^2$$
 평균 제곱 오차(MSE) $=\frac{1}{n}\sum_{i=1}^n \left(p_i-y_i\right)^2$

평균 제곱근 오차(RMSE)
$$=\sqrt{rac{1}{n}{\sum_{i=1}^{n}{\left(p_i-y_i
ight)^2}}}$$

y = 3x + 76식의 데이터에 대한 오차의 값

선형 회귀란 임의의 직선을 그어 이에 대한 평균 제곱근 오차를 구하고, 이 값을 가장 작게 만들어 주는 a와 b 값을 찾아가는 작업입니다.

▶ 평균 제곱근 오차(root mean square error) 구현 코드

```
import numpy as np
# 기울기 a와 v 절편 b
ab = [3, 76]
# x, v의 데이터 값
data = [[2, 81], [4, 93], [6, 91], [8, 97]]
x = [i[0] \text{ for } i \text{ in data}]
y = [i[1] \text{ for } i \text{ in data}]
# y = ax + b에 a와 b 값을 대입하여 결과를 출력하는 함수
def predict(x):
  return ab[0]*x + ab[1]
# RMSE 함수
def rmse(p, a):
  return np.sqrt(((p - a) ** 2).mean())
# RMSE 함수를 각 v 값에 대입하여 최종 값을 구하는 함수
def rmse val(predict result,y):
  return rmse(np.array(predict_result), np.array(y))
```

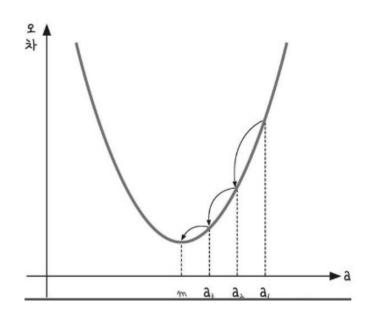
```
# 예측 값이 들어갈 빈 리스트
predict_result = []

# 모든 x 값을 한 번씩 대입하여
for i in range(len(x)):
  # predict_result 리스트를 완성한다.
  predict_result.append(predict(x[i]))
  print("공부한 시간 = %.f, 실제 점수 = %.f, 예측 점수
= %.f" % (x[i], y[i], predict(x[i])))

# 최종 RMSE 출력
print("rmse 최종값: " + str(rmse_val(predict_result,y)))
```

➤ 오차 수정 – 경사하강법(gradient decent)

■ 기울기 a를 무한대로 키우면 오차도 무한대로 커지고 a를 무한대로 작게 해도 역시 오차도 무한대로 작아지는 상관관계는 이차 함수 그래프로 표현할 수 있습니다.

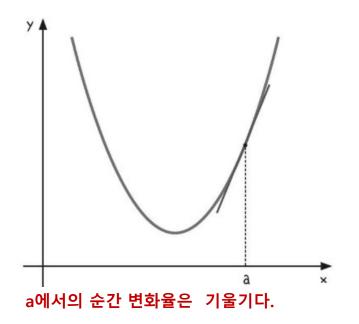


- 오차가 가장 작을 때는 x가 그래프의 가장 아래쪽의 볼록한 부분에 이르렀을 때입니다.
- 즉, 기울기 a가 m 위치에 있을 때입니다.
- 컴퓨터를 이용해 m의 값을 구하려면 임의의 한 점(a1)을 찍고 이 점을 m에 가까운 쪽으로 점점 이동(a1 → a2 → a3)시키는 과정이 필요합니다.
- (a1의 값보다 a2의 값이 m에 더 가깝고 a2의 값보다 a3가 m에 더 가깝다는 것을 컴퓨터가 알아야 하겠지요)
- 미분 기울기를 이용하는 경사 하강법(gradient decent)은 이차 함수 그래프에서 오차를 비교하여 가장 작은 방향으로 이동시키는 방법입 니다

기울기 a와 오차와의 관계: 적절한 기울기를 찾았을 때 오차가 최소화된다.

> 미분

- Y = X² 이라는 그래프의 x축에 한 점 a가 있을 때 y 값은 Y = a² 입니다.
- a가 아주 미세하게 오른쪽이나 왼쪽으로 이동하면 종속 변수인 y 값도 그에 따라 아주 미세하게 변화합니다.
- a가 변화량이 0에 가까울 만큼 아주 미세하게 변화하면 y 값의 변화 역시 아주 미세해서 0에 가깝게 변화합니다. (순간변화율)
- 순간 변화율은 '어느 쪽'이라는 방향성을 지니고 있으므로 이 방향에 맞추어 직선(점에서의 '기울기', 접선)을 그릴 수가 있습니다.
- 미분은 x 값이 아주 미세하게 움직일 때의 y 변화량을 구한 뒤, 이를 x의 변화량으로 나누는 과정입니다.



"함수
$$f(x)$$
를 미분하라" $\frac{d}{dx}f(x)$

$$\frac{d}{dx}f(x) = \lim_{\Delta x \to 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}$$
 ④ 3 y 변화량의 차이를 ④ x 변화량으로 나눈 값(= 순간 변화율)을 구하라는 뜻 ② x의 변화량이 0에 가까울 만큼 작을 때 ① 함수 f(x)를 x로 미분하라는 것은

- 도함수: 어떤 함수 안에 포함도니 값 각각이 0에 한없이 가까워지는 극한값(미분계수)을 구하는 함수
- y = f(x)의 도함수 f' (x)는 아래와 같이 정의

$$f'(x) = \lim_{\Delta x \to 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}$$

• f(x) = 3x일 때, 도함수 계산 과정

$$f'(x) = \lim_{\Delta x \to 0} \frac{3(x + \Delta x) - 3x}{\Delta x} = \lim_{\Delta x \to 0} \frac{3\Delta x}{\Delta x} = 3$$

• f(x) = x^2일떄, 도함수 계산 과정

$$\begin{split} f'(x) &= \lim_{\Delta x \to 0} \frac{(x + \Delta x)^2 - x^2}{\Delta x} = \lim_{\Delta x \to 0} \frac{2x\Delta x + (\Delta x)^2}{\Delta x} \\ &= \lim_{\Delta x \to 0} (2x + \Delta x) = 2x \end{split}$$

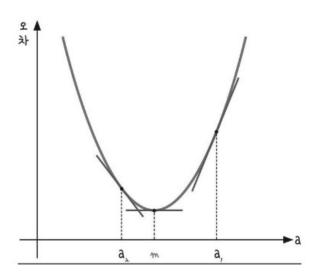
• 함수 f(x)의 도함수f' (x)를 구하는 것을 "함수 f(x)를 미분한다" 라고 하며, 위와 같이 값을 계산할 수 있다면 미분 가능이라고 함

▶ 미분 결과

- f(x) = a(a는 상수)일 때 미분 값은 0
- f(x) = x일 때 미분 값은 1
- f(x) = ax(a는 상수)일 때 미분 값은 a
- f(x) = X^a (a는 자연수)일 때 미분 값은 ax^{a-1}

> 경사하강법(gradient decent)

- y = X² 그래프에서 X에 a_{1.}a₂그리고 m을 대입하여 미분하면 각 점에서의 순간 기울기가 그려집니다.
- 순간 기울기가 0인 점이 최솟값 m이다.
- 그래프가 이차 함수 포물선이므로 꼭짓점의 기울기는 x축과 평행한 선이 되며, 기울기가 0입니다.
- 경사 하강법은 반복적으로 기울기 a를 변화시켜서 m의 값을 찾아내는 방법 ('미분 값이 0인 지점'을 찾는 것)입니다.



호 차 a, a, m a, a, a

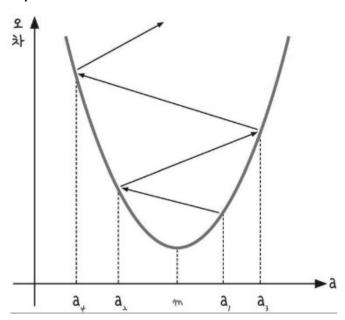
• a1에서 미분을 구한다.

- 구해진 기울기의 반대 방향(기울기가 + 면 음의 방향, -면 양의 방향)으로 얼마 간 이동시킨 a2에서 미분을 구한다
- a3에서 미분을 구한다.
- 0이 아니면 위 과정을 반복한다.

a순간 기울기가 0인 점이 최솟값 m이다.

학습률(learning rate)

- 기울기의 부호를 바꿔 이동시킬 때 적절한 거리를 찾지 못해 너무 멀리 이동시키면 a 값이 한 점으로 모이지 않고 위로 치솟아 버립니다
- 이동 거리를 정해주는 것이 바로 학습률(learning rate)입니다.
- 딥러닝에서 학습률의 값을 적절히 바꾸면서 최적의 학습률을 찾는 것은 중요한 최적화 과정 중 하나입니다..



케라스는 학습률을 자동으로 조절해 줍니다

학습률을 너무 크게 잡으면 한 점으로 수렴하지 않고 발산한다.

➤ 경사하강법(gradient decent) 코드 구현

- 경사 하강법은 오차의 변화에 따라 이차 함수 그래프를 만들고 적절한 학습률을 설정해 미분 값이 0인 지점을 구하는 것입니다.
- y 절편 b의 값도 b 값이 너무 크면 오차도 함께 커지고 너무 작아도 오차가 커집니다.
- 최적의 b 값을 구할 때 역시 경사 하강법을 사용합니다.
- GradientDescentOptimizer(): 경사 하강법 함수
- 텐서플로는 session 함수를 이용해 구동에 필요한 리소스를 컴퓨터에 할당하고 이를 실행시킬 준비를 합니다.
- Session을 통해 구현될 함수를 텐서플로에서는 '그래프'라고 부른다
- Session이 할당되면 session.run('그래프명')의 형식으로 해당 함수를 실행시킵니다.
- global_variables_initializer(): 변수를 초기화하는 함수
- gradient_decent : 총 필요한 수만큼 반복하여 실행

➤ 경사하강법(gradient decent) 코드 구현

```
import tensorflow as tf
# x, v의 데이터 값
data = [[2, 81], [4, 93], [6, 91], [8, 97]]
x_{data} = [x_{row}[0] \text{ for } x_{row} \text{ in data}]
y_data = [y_row[1] for y_row in data]
# 기울기 a와 y 절편 b의 값을 임의로 정한다.
# 단, 기울기의 범위는 0 ~ 10 사이이며, v 절편은 0 ~ 100 사이에서 변하게 한다.
a = tf.Variable(tf.random_uniform([1], 0, 10, dtype = tf.float64,seed = 0))
b = tf.Variable(tf.random uniform([1], 0, 100, dtype = tf.float64, seed = 0))
# y에 대한 일차 방정식 ax+b의 식을 세운다.
y = a * x data + b
# 텐서플로 RMSE 함수
rmse = tf.sqrt(tf.reduce_mean(tf.square( y - y_data )))
# 학습률 값
learning_rate = 0.1
```

➤ 경사하강법(gradient decent) 코드 구현

```
# RMSE 값을 최소로 하는 값 찾기
gradient_decent = tf.train.GradientDescentOptimizer(learning_rate).minimize(rmse)

# 텐서플로를 이용한 학습
with tf.Session() as sess:
# 변수 초기화
sess.run(tf.global_variables_initializer())
# 2001번 실행(0번째를 포함하므로)
for step in range(2001):
sess.run(gradient_decent)
# 100번마다 결과 출력
if step % 100 == 0:
print("Epoch: %.f, RMSE = %.04f, 기울기 a = %.4f, y 절편
b = %.4f" % (step,sess.run(rmse),sess.run(a),sess.run(b)))
```

• 에포크(Epoch)는 입력 값에 대해 몇 번이나 반복하여 실험했는지를 나타냅니다.

▶ 경사 하강법으로 다중 선형 회귀 구현 코드

공부한 시간(x ₁)	2	4	6	8
과외 수업 횟수(x2)	0	4	2	3
성적(y)	81	93	91	97

$$y = a_1x_1 + a_2x_2 + b$$

```
import tensorflow as tf

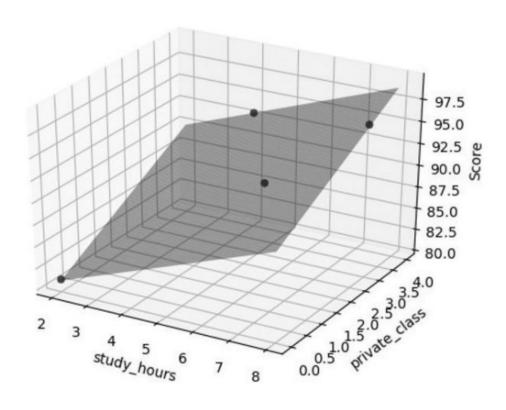
# x1, x2, y의 데이터 값
data = [[2, 0, 81], [4, 4, 93], [6, 2, 91], [8, 3, 97]]
x1 = [x_row1[0] for x_row1 in data]
x2 = [x_row2[1] for x_row2 in data] # 새로 추가되는 값
y_data = [y_row[2] for y_row in data]

# 기울기 a와 y 절편 b의 값을 임의로 정한다.
# 단, 기울기의 범위는 0 ~ 10 사이이며, y 절편은 0 ~ 100 사이에서 변하게 한다.
a1 = tf.Variable(tf.random_uniform([1], 0, 10, dtype=tf.float64, seed=0))
a2 = tf.Variable(tf.random_uniform([1], 0, 10, dtype=tf.float64, seed=0))
b = tf.Variable(tf.random_uniform([1], 0, 100, dtype=tf.float64, seed=0))
```

▶ 경사 하강법으로 다중 선형 회귀 구현 코드

```
# 새로운 방정식
y = a1 * x1 + a2 * x2 + b
# 텐서플로 RMSE 함수
rmse = tf.sqrt(tf.reduce mean(tf.square( y - y data )))
# 학습률 값
learning rate = 0.1
# RMSE 값을 최소로 하는 값 찾기
gradient_decent = tf.train.GradientDescentOptimizer(learning_rate).minimize(rmse)
# 학습이 진행되는 부분
with tf.Session() as sess:
   sess.run(tf.global_variables_initializer())
  for step in range(2001):
     sess.run(gradient_decent)
     if step % 100 == 0:
        print("Epoch: %.f, RMSE = %.04f, 기울기 a1 = %.4f, 기울기 a2 = %.4f, y 절편 b = %.4f" %
(step,sess.run(rmse),sess.run(a1), sess.run(a2),sess.run(b)))
```

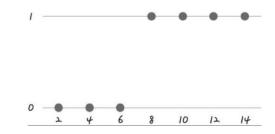
> 경사 하강법으로 다중 선형 회귀 구현 코드

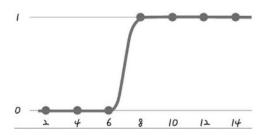


▶ 로지스틱 회귀(logistic regression)

■ 로지스틱 회귀는 선형 회귀와 마찬가지로 적절한 선을 그려가는 과정입니다. 다만, 직선이 아니라, 참(1)과 거짓(0) 사이를 구분하는 S자 형태의 선을 그어 주는 작업입니다.

공부한 시간	2	4	6	8	10	12	14
합격 여부	불합격	불합격	불합격	합격	합격	합격	합격

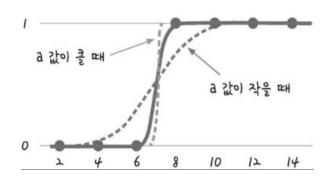


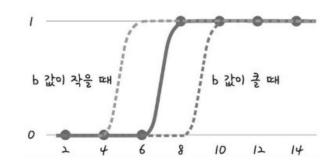


> 시그모이드 함수(sigmoid function)

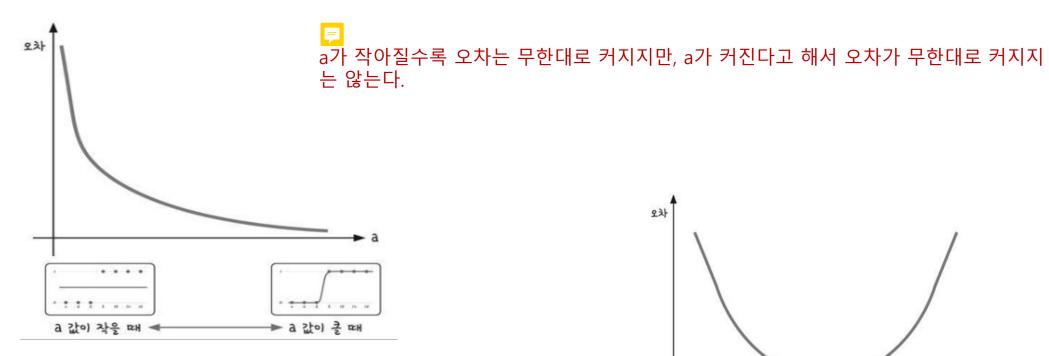
- S자 형태로 그래프가 그려지는 함수
- e는 자연 상수라고 불리는 무리수로 값은 2.71828...입니다.
- a는 그래프의 경사도를 결정합니다.
- a 값이 커지면 경사가 커지고 a 값이 작아지면 경사가 작아집니다
- b는 그래프의 좌우 이동을 의미합니다.
- b 값이 크고 작아짐에 따라 그래프가 이동합니다.

$$y = \frac{1}{1 + e^{(ax+b)}}$$

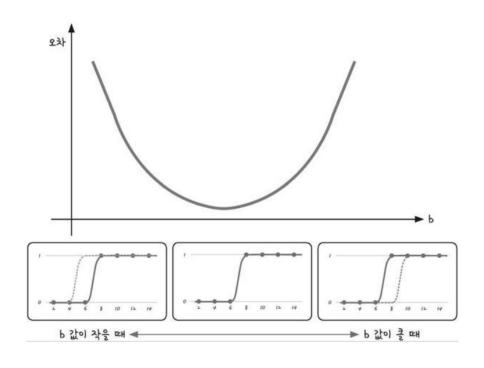




➤ 시그모이드 함수(sigmoid function)



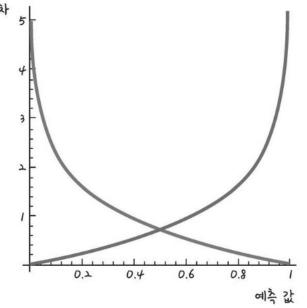
b 값이 너무 작아지거나 커지면 오차도 무한대로 커진다. 이차 함수 그래프로 표현할 수 있습니다.



- ▶ 오차공식
 - 시그모이드 함수에서 a와 b의 값은 경사 하강법(오차를 구한 다음 오차가 작은 쪽으로 이동시키는 방법) 으로 구합니다
 - 시그모이드 함수의 특징은 y 값이 0과 1 사이 입니다.
 - 실제 값이 1일 때 예측 값이 0에 가까워지면 오차가 커져야 합니다.
 - 실제 값이 0일 때 예측 값이 1에 가까워지는 경우에도 오차는 커져야 합니다.

예측 값이 1일 때 오차가 0이고, 예측 값이 0에 가까울수록 오차는 커지는 로그함수 그래프

-log h



예측 값이 0일 때 오차가 없고, 1에 가까 워질수록 오차가 매우 커지는 로그 함수 그래프

-log (1 - h)

- ▶ 로그 함수
 - y의 실제 값이 1일 때 -log h 그래프를 쓰고, 0일 때 -log (1 h) 그래프를 써야 합니다.

$$-\{y\log h + (1-y)\log(1-h)\}$$

■ 실제 값 y가 1이면 B 부분이 없어집니다. 반대로 0이면 A 부분이 없어집니다.

▶ 로지스틱 회귀 구현 코드

```
import tensorflow as tf
import numpy as np
# x, y의 데이터 값
data = [[2, 0], [4, 0], [6, 0], [8, 1], [10, 1], [12, 1], [14,1]]
x_{data} = [x_{row}[0] \text{ for } x_{row} \text{ in data}]
y data = [y row[1] for y row in data]
# a와 b의 값을 임의로 정한다.
a = tf.Variable(tf.random_normal([1], dtype=tf.float64, seed=0))
b = tf.Variable(tf.random normal([1], dtype=tf.float64, seed=0))
# y 시그모이드 함수의 방정식을 세운다.
y = 1/(1 + np.e^{**}(a * x_data + b))
# loss를 구하는 함수
loss = -tf.reduce_mean(np.array(y_data) * tf.log(y) + (1 -np.array(y_data)) * tf.log(1 - y))
# 학습률 값
learning rate = 0.5
```

▶ 로지스틱 회귀 구현 코드

- 여러 입력 값을 갖는 로지스틱 회귀 코드 구현
 - tf.placeholder('데이터형', '행렬의 차원', '이름') 는 입력 값을 저장하는데 사용합니다...
 - a₁x₁ + a₂x₂는 행렬곱을 이용해 [a₁, a] * [x₁, x₂]로도 표현할 수 있습니다
 - 텐서플로에서는 matmul() 함수를 이용해 행렬곱을 적용합니다
 - 텐서플로 내장 sigmoid() 함수 시그모이드를 계산

```
import tensorflow as tf import numpy as np

# 실행할 때마다 같은 결과를 출력하기 위한 seed 값 설정 seed = 0 np.random.seed(seed) 
tf.set_random_seed(seed)

# x, y의 데이터 값 x_data = np.array([[2, 3],[4, 3],[6, 4],[8, 6],[10, 7],[12,8],[14, 9]]) 
y_data = np.array([0, 0, 0, 1, 1, 1,1]).reshape(7, 1)

# 입력 값을 플레이스 홀더에 저장 X = tf.placeholder(tf.float64, shape=[None, 2]) 
Y = tf.placeholder(tf.float64, shape=[None, 1])
```

여러 입력 값을 갖는 로지스틱 회귀 코드 구현

```
# 기울기 a와 바이어스 b의 값을 임의로 정함
a = tf.Variable(tf.random_uniform([2,1], dtype=tf.float64))
# [2,1] 의미: 들어오는 값은 2개, 나가는 값은 1개
b = tf.Variable(tf.random uniform([1], dtype=tf.float64))
                                                               # y 시그모이드 함수의 방정식을 세움
y = tf.sigmoid(tf.matmul(X, a) + b)
                                                         # 오차를 구하는 함수
loss = -tf.reduce mean(Y * tf.log(y) + (1 - Y) * tf.log(1 - y))
                                                               # 학습률 값
learning rate=0.1
# 오차를 최소로 하는 값 찾기
gradient decent = tf.train.GradientDescentOptimizer(learning rate).minimize(loss)
predicted = tf.cast(y > 0.5, dtype=tf.float64)
accuracy = tf.reduce mean(tf.cast(tf.equal(predicted, Y), dtype=tf.float64))
                                                                # 학습
with tf.Session() as sess:
  sess.run(tf.global_variables_initializer())
  for i in range(3001):
     a_, b_, loss_, _ = sess.run([a, b, loss, gradient_decent], feed_dict={X: x_data, Y: y_data})
     if (i + 1) \% 300 == 0:
        print("step=%d, a1=%.4f, a2=%.4f, b=%.4f, loss=%.4f"% (i + 1, a [0], a [1], b , loss ))
```

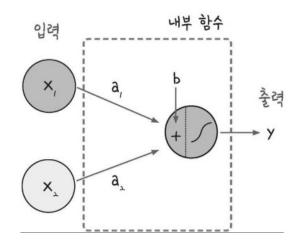
▶ 여러 입력 값을 갖는 로지스틱 회귀 – 새로운 데이터에 대한 예측값 생성

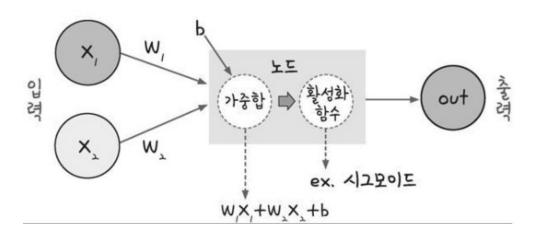
```
new_x = np.array([7, 6.]).reshape(1, 2) # [7, 6]은 각각 공부한 시간과 과외 수업 횟수 new_y = sess.run(y, feed_dict={X: new_x})
print("공부한 시간: %d, 과외 수업 횟수: %d" % (new_x[:,0], new_x[:,1]))
print("합격 가능성: %6.2f %%" % (new_y*100))
```

➤ 퍼셉트론(perceptron)

- 뉴런과 뉴런이 서로 새로운 연결을 만들기도 하고 필요에 따라 위치를 바꾸는 것처럼, 여러 층의 퍼셉트 론을 서로 연결시키고 복잡하게 조합하여 주어진 입력 값에 대한 판단을 하게 하는 것
- 퍼셉트론은 입력 값과 활성화 함수를 사용해 출력 값을 다음으로 넘기는 가장 작은 신경망 단위
- N개의 이진수가 하나의 뉴런을 통과해서 가중합 0보다 크면 활성화되는 가장 간단한 신경망 구조
- 초평면(hyperplane)으로 구분되는 두 개의 공간을 분리시키는 역할을 한다
- AND 게이트 , OR 게이트를 만들 수 있다.

$$y = a_1x_1 + a_2x_2 + b$$



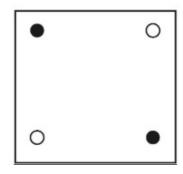


➤ 퍼셉트론(perceptron)

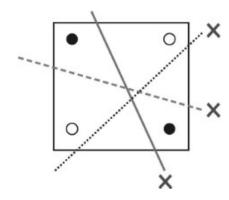
- 가중합 입력 값(x)과 가중치(w)의 곱을 모두 더한 값에 바이어스(b)를 더한 값
- 가중합의 결과를 놓고 1 또는 0을 출력해서 다음으로 보냅니다.
- 활성화 함수(activation function) 0과 1을 판단하는 함수

y = wx + b (w는 가중치, b는 바이어스)

➤ XOR(exclusive OR) 문제

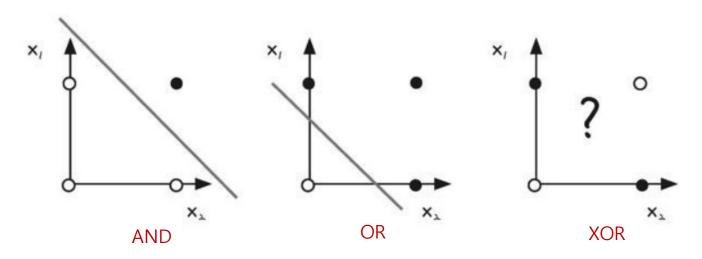


직선의 한쪽 편에는 검은점만 있고, 다른 한쪽에는 흰점만 있게끔 선을 그을 수 있을까요?.



> XOR(exclusive OR) 문제

- XOR(exclusive OR) 둘 중 하나만 1일 때 1이 출력
- 결괏값이 0이면 흰점으로, 1이면 검은점으로 각각 그래프로 좌표 평면에 표현



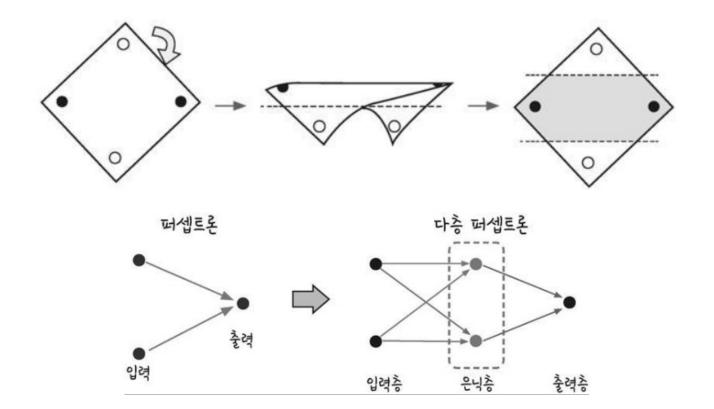
XOR 진리표

X ₁	X ₂	결괏값
0	0	0
0	1	1
1	0	1
1	1	0

AND와 OR 게이트는 직선을 그어 결괏값이 1인 값(검은점)을 구별할 수 있습니다. XOR의 경우 선을 그어 구분할 수 없습니다.

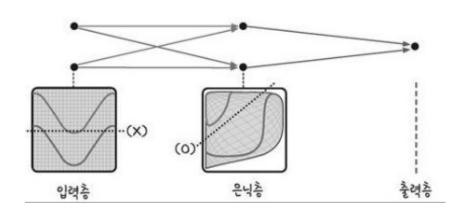
➤ XOR(exclusive OR) 문제

- 좌표 평면 자체에 변화를 주는 것
- XOR 문제를 해결하기 위해서 우리는 두 개의 퍼셉트론을 한 번에 계산할 수 있어야 합니다.
- 은닉층(hidden layer)



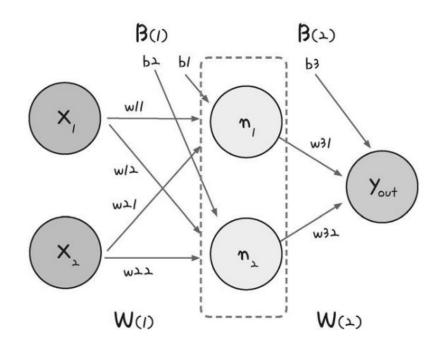
➤ 퍼셉트론(perceptron)

- 입력 값(input)을 놓고 파란색(위)과 빨간색(아래)의 영역을 구분한다고 할 때, 왼쪽은 어떤 직선으로도 이를 해결할 수 없습니다.
- 은닉층을 만들어 공간을 왜곡하면 두 영역을 가로지르는 선이 직선으로 바뀝니다
- 은닉층이 좌표 평면을 왜곡시키는 결과를 가져옵니다.



▶ 다층 퍼셉트론(perceptron)

- 은닉층으로 퍼셉트론이 각각 자신의 가중치(w)와 바이어스(b) 값을 보내고
- 은닉층에서 모인 값이 한 번 더 시그모이드 함수(기호로 σ 라고 표시합니다)를 이용해 최종 값으로 결과 를 보냅니다.
- 은닉층에 모이는 중간 정거장을 노드(node)라고 하며, (n1과 n2)
- 은닉층의 노드 n1과 n2의 값은 각각 단일 퍼셉트론의 값과 같습니다.



$$n_1 = \sigma(x_1 w_{11} + x_2 w_{21} + b_1)$$

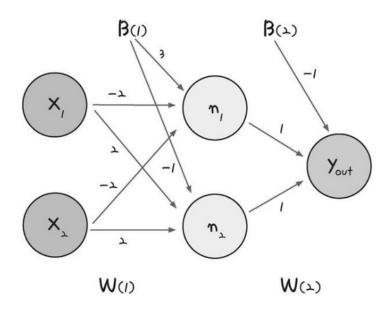
$$n_2 = \sigma(x_2 w_{21} + x_2 w_{22} + b_2)$$

- 두 식의 결괏값이 출력층으로 보내집니다.
- 출력층에서는 시그모이드 함수를 통해 y 값이 정해 집니다.

$$y_{out} = \sigma(n_1 w_{31} + n_2 w_{32} + b_3)$$

> XOR 문제의 해결

$$W(1) = \begin{bmatrix} -2 & 2 \\ -2 & 2 \end{bmatrix} \quad B(1) = \begin{bmatrix} 3 \\ -1 \end{bmatrix}$$
$$W(2) = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \qquad B(2) = \begin{bmatrix} -1 \end{bmatrix}$$



X ₁	X ₂	n ₁	n ₂	Yout	우리가 원하는 값
0	0	$\sigma(0 * (-2) + 0 *$ $(-2) + 3) = 1$	σ(0 * 2 + 0 * 2 - 1) = 0	σ(1 * 1 + 0 * 1 - 1) = 0	0
0	1	$\sigma(0 * (-2) + 1 *$ (-2) + 3) = 1	σ(0 * 2 + 1 * 2 - 1) = 1	σ(1 * 1 + 1 * 1 - 1) = 1	1
1	0		σ(1 * 2 + 0 * 2 - 1) = 1	σ(1 * 1 + 1 * 1 - 1) = 1	1
1	1		σ(1 * 2 + 1 * 2 - 1) = 1		0

> XOR 문제의 해결 코드 구현

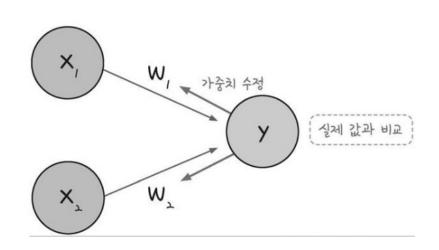
```
import numpy as np
# 가중치와 바이어스
w11 = np.array([-2, -2])
w12 = np.array([2, 2])
w2 = np.array([1, 1])
b1 = 3
b2 = -1
b3 = -1
# 퍼셉트론
def MLP(x, w, b):
  y = np.sum(w * x) + b
  if y <= 0:
     return 0
  else:
     return 1
# NAND 게이트
def NAND(x1, x2):
  return MLP(np.array([x1, x2]), w11, b1)
```

> XOR 문제의 해결 코드 구현

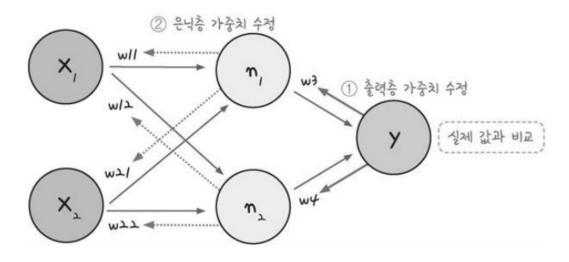
```
# OR 게이트
def OR(x1, x2):
  return MLP(np.array([x1, x2]), w12, b2)
# AND 게이트
def AND(x1, x2):
  return MLP(np.array([x1, x2]), w2, b3)
# XOR 게이트
def XOR(x1, x2):
  return AND(NAND(x1, x2),OR(x1, x2))
# x1, x2 값을 번갈아 대입해 가며 최종값 출력
if _ _name_ _ == '_ _main_ _':
  for x in [(0, 0), (1, 0), (0, 1), (1, 1)]:
     y = XOR(x[0], x[1])
     print("입력 값: " + str(x) + " 출력 값: " + str(y))
```

> 오차 역전파

- 신경망 내부의 가중치는 오차 역전파 방법을 사용해 수정합니다.
- 임의의 가중치를 선언하고 최소 제곱법을 이용해 오차를 구한 뒤 이 오차가 최소인 지점으로 계속해서 조금씩 이동시킵니다.
- 오차가 최소가 되는 점(미분했을 때 기울기가 0이 되는 지점)이 우리가 알고자 하는 답입니다



단일 퍼셉트론에서의 오차 수정



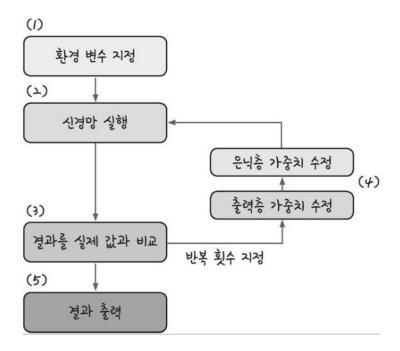
다층 퍼셉트론에서의 오차 수정

- 오차 역전파 (back propagation)
 - 다층 퍼셉트론에서의 최적화 과정
 - 가중치에서 기울기를 빼도 값의 변화가 없을 때까지 계속해서 가중치 수정 작업을 반복하는 것
 - 출력층으로부터 하나씩 앞으로 되돌아가며 각 층의 가중치를 수정하는 방법
 - 가중치를 수정하려면 미분 값, 즉 기울기가 필요합니다

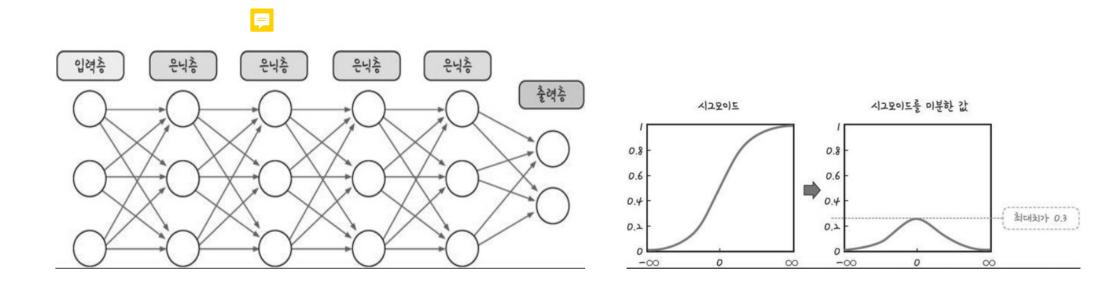
새 가중치는 현 가중치에서 '가중치에 대한 기울기'를 뺀 값!

$$W(t+1) = Wt - \frac{\partial \mathcal{L}^{\lambda}}{\partial W}$$

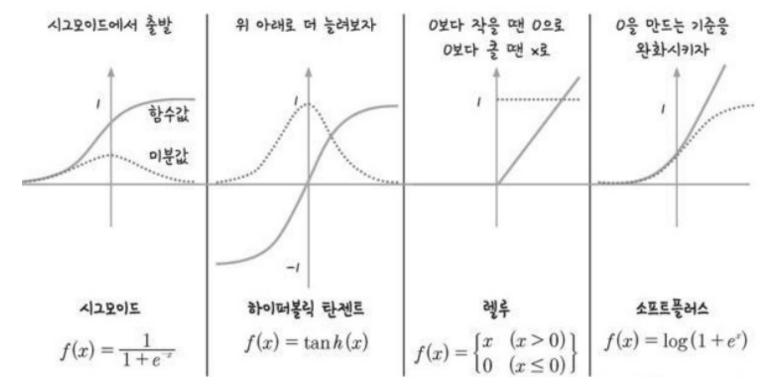
편미분 기호 ∂(partial, 파셜)



- ▶ 활성화 함수 기울기 소실 문제 해결
 - 활성화 함수 시그모이드는 층이 늘어나면서 기울기가 중간에 0이 되어버리는 기울기 소실(vanishing gradient) 문제가 발생합니다.
 - 시그모이드를 미분하면 최대치가 0.3입니다. 1보다 작으므로 계속 곱하다 보면 0에 가까워집니다.
 - 시그모이드는 층을 거쳐 갈수록 기울기가 사라져 가중치를 수정하기가 어려워집니다.



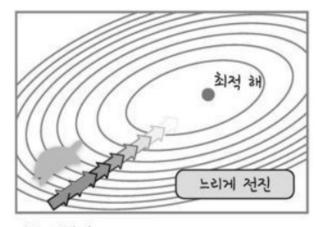
- ▶ 활성화 함수 기울기 소실 문제 해결
 - 기울기가 사라지는 문제를 해결하기 위해 활성화 함수를 시그모이드가 아닌 여러 함수로 대체하기 시작



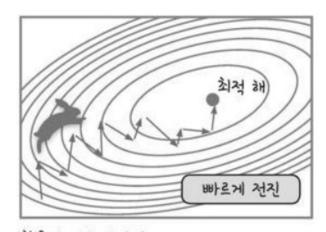
- 하이퍼볼릭 탄젠트(tanh) 시그모이드 함수의 범위를 -1에서 1로 확장, 미분한 값의 범위가 함께 확장 되는 효과를 가져왔습니다. 여전히 1보다 작은 값이 존재하므로 <mark>기울기 소실 문제는 사라지지 않습니다.</mark>
- <mark>렐루(ReLU)</mark> x가 0보다 작을 때는 모든 값을 0으로 처리하고, 0보다 큰 값은 x를 그대로 사용하는 방법 x가 0보다 크기만 하면 미분 값이 1이 됩니다. 따라서 여러 은닉층을 거치며 곱해지더라도 맨 처음 층까지 사라지지 않고 남아있을 수 있습니다.

▶ 확률적 경사 하강법(SGD)

- 경사 하강법은 정확하게 가중치를 찾아가지만, 한 번 업데이트할 때마다 전체 데이터를 미분해야 하므로 계산량이 매우 많다는 단점이 있습니다.
- 확률적 경사 하강법은 전체 데이터를 사용하는 것이 아니라, 랜덤하게 추출한 일부 데이터를 사용합니다.
 일부 데이터를 사용하므로 더 빨리, 자주 업데이트를 하는 것이 가능해졌습니다.
- 확률적 경사 하강법은 중간 결과의 진폭이 크고 불안정해 보일 수도 있습니다.
- 속도가 빠르면서도 최적 해에 근사한 값을 찾아낸다는 장점 때문에 경사 하강법의 대안으로 사용되고 있습니다.



경사 하강법

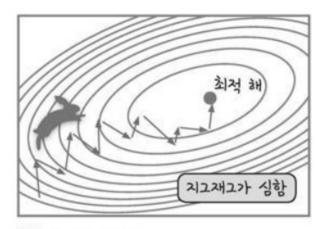


확률적 경사 하강법

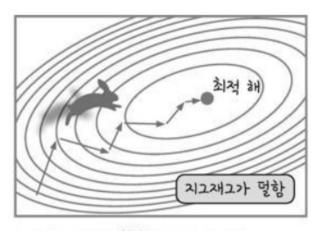
➤ 모멘텀(momentum)

- 관성, 탄력, 가속도라는 뜻
- 모멘텀 SGD- 경사 하강법에 탄력을 더해 주는 것

경사 하강법과 마찬가지로 매번 기울기를 구하지만, 이를 통해 오차를 수정하기 전 바로 앞수정 값과 방향(+, -)을 참고하여 같은 방향으로 일정한 비율만 수정되게 하는 방법수정 방향이 양수(+) 방향으로 한 번, 음수(-) 방향으로 한 번 지그재그로 일어나는 현상이줄어들고, 이전 이동 값을 고려하여 일정 비율만큼만 다음 값을 결정하므로 관성의 효과를 낼 수 있습니다.



확률적 경사 하강법



모엔텀을 적용한 확률적 경사 하강법

고급 경사 하강법의 케라스 사용법

고급 경사 하강법	개요	효과	케라스 사용법
확률적 경사 하강법 (SGD)	랜덤하게 추출한 일부 데이터를 사용해 더 빨리, 자주 업데이트를 하게 하는 것	속도 개선	keras.optimizers.SGD(lr = 0.1) 케라스 최적화 함수를 이용
모멘텀 (Momentum)	관성의 방향을 고려해 진동과 폭을 줄이는 효과	정확도 개선	keras.optimizers.SGD(lr =0.1, momentum= 0.9) 모멘텀 계수를 추가
네스테로프 모멘텀 (NAG)	변수의 업데이트가 잦으면 학습률을 적게하여 이동 보폭을 조절하는 방법	보폭 크기 개선	keras.optimizers.Adagrad(lr = 0.01, epsilon = 1e - 6) 아다그라드 함수를 사용
알엠에스프롭 (RMSProp)	아다그라드의 보폭 민감도를 보완한 방법	보폭 크기 개선	keras.optimizers.RMSprop(lr = 0.001, rho = 0.9, epsilon = 1e - 08, decay = 0.0) 알엠에스프롭 함수를 사용합니다.
아담(Adam)	<mark>모멘텀</mark> 과 <mark>알엠에스프롭</mark> 방법을 합친 방법	정확도와 보폭 크기 개선	keras.optimizers.Adam(lr = 0.001, beta_1 = 0.9, beta_2 = 0.999, epsilon = 1e - 08, decay = 0.0) 아담 함수를 사용합니다.

▶ 폐암 수술 환자의 생존율 예측하기 실습

```
# 딥러닝을 구동하는 데 필요한 케라스 함수를 불러옵니다.
from keras.models import Sequential
from keras.layers import Dense
# 필요한 라이브러리를 불러옵니다.
import numpy
import tensorflow as tf
# 실행할 때마다 같은 결과를 출력하기 위해 설정하는 부분입니다.
seed = 0
numpy.random.seed(seed)
tf.set random seed(seed)
# 준비된 수술 환자 데이터를 불러들입니다.
Data set = numpy.loadtxt("./dataset/ThoraricSurgery.csv",delimiter=",")
# 환자의 기록과 수술 결과를 X와 Y로 구분하여 저장합니다.
X = Data set[:,0:17]
Y = Data set[:,17]
```

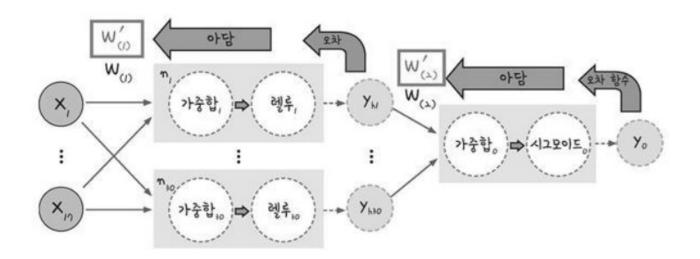
▶ 폐암 수술 환자의 생존율 예측하기 실습

```
# 딥러닝 구조를 결정합니다(모델을 설정하고 실행).
model = Sequential() #딥러닝의 구조를 짜고 층을 설정
# 첫 번째 은닉층에 input_dim을 적어 줌으로써 첫 번째 Dense가 은닉층 + 입력층의 역할을 겸합니다.
# 데이터에서 17개의 값을 받아 은닉층의 30개 노드로 보낸다
model.add(Dense(30, input_dim=17, activation='relu')) #activation: 출력층으로 전달할 때 사용할 활성화 함수
model.add(Dense(1, activation='sigmoid')) #출력층의 노드 수는 1개, 최종 출력 값에 사용될 활성화 함수
# 딥러닝을 실행합니다. (오차 함수: 평균 제곱 오차 함수 사용)
model.compile(loss='mean_squared_error', optimizer='adam',metrics=['accuracy'])
model.fit(X, Y, epochs=30, batch_size=10)
# 결과를 출력합니다.
print("\underwarpun Accuracy: %.4f" % (model.evaluate(X, Y)[1]))
```

- 평균 제곱 오차는 수렴하기까지 속도가 많이 걸린다는 단점이 있다
- 교차 엔트로피는 출력 값에 로그를 취해서, 오차가 커지면 수렴 속도가 빨라지고 오차가 작아지면 속도가 감소하게 끔 만듭니다.
- metrics 함수는 모델이 컴파일될 때 모델 수행 결과를 나타내게끔 설정하는 부분입니다. 정확도를 측정하기 위해 사용되는 테스트 샘플을 학습 과정에서 제외시킴으로써 과적합 문제(over fitting, 특정 데이터에서는 잘 작동하나 다른 데이터에서는 잘 작동하지 않는 문제)를 방지하는 기능을 담고 있습니다.

▶ 폐암 수술 환자의 생존율 예측하기 실습

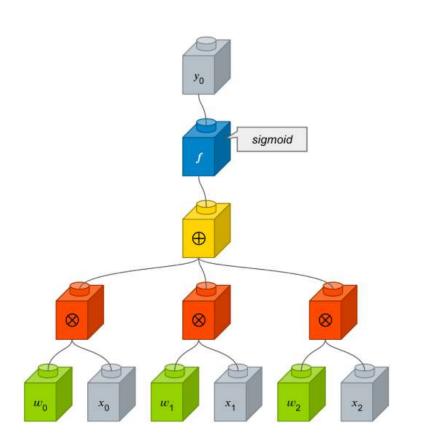
- 학습 프로세스가 모든 샘플에 대해 한 번 실행되는 것을 1 epoch('에포크'라고 읽습니다)라고 합니다.
- epochs=1000은 각 샘플이 처음부터 끝까지 1,000번 재사용될 때까지 실행을 반복하라는 뜻입니다.
- batch_size는 샘플을 한 번에 몇 개씩 처리할지를 정하는 부분입니다.
- batch_size=10은 전체 470개의 샘플을 10개씩 끊어서 집어넣으라는 뜻이 됩니다.
- batch_size가 너무 크면 학습 속도가 느려지고, 너무 작으면 각 실행 값의 편차가 생겨서 전체 결괏값이 불안정해질 수 있습니다.

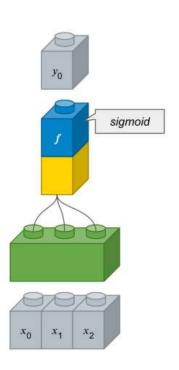


Keras

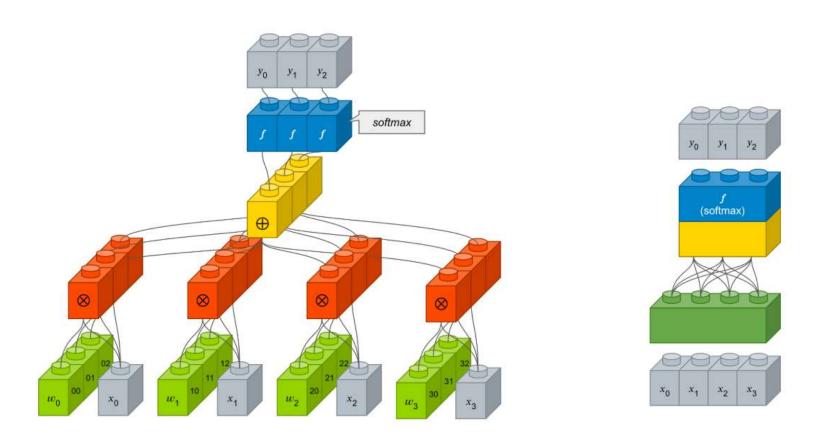
- weight decay(가중치 감소) 학습중 가중치가 큰 것에 대해서 패널티를 부과해 과적합의 위험을 줄이는 방법
- Dropout 복잡한 신경망에서 가중치 감소만으로 과적합을 피하기 어려운 경우 뉴런의 연결을 임의로 삭제시켜 신호를 전달하지 못하도록 하는 방법
- softmax 회귀 입력받은 값을 출력으로 0~1사이의 값으로 모두 정규화하여 출력값들의 총합은 항상 1이 되는 특성의 함수
- 분류하고 싶은 클래스 수 만큼 출력으로 구성
- 소프트 맥스 결과값을 One hot encoder의 입력으로 연결하면 가장 큰 값만 True값, 나머지는 False값이 나오게 하여 이용 가능하다
- val loss는 에포크 힛수가 많아질 수록 감소하다가 다시 증가됨을 보이는 경우, 과적합이 발생한 것입니다.
- 학습에 더 이상 개선의 여지가 없을 경우 학습을 종료시키는 콜백함수(수행중인 함수에서 지정된 함수를 호출,되부름) 는 EarlyStopping 입니다.
- Dense(출력 뉴런의 수, input_dim=입력 뉴런의 수, init= 가중치 초기화 방법, activation=활성화 함수)
- relu 활성화 함수는 은닉층에 주로 사용
- sigmoid 활성화 함수는 이진 분류 문제에서 출력층에 주로 사용
- softmax 활성화 함수는 다중 클래스 분류 문제에서 출력층에 주로 사용

Dense(1, input_dim=3, activation='sigmoid'))

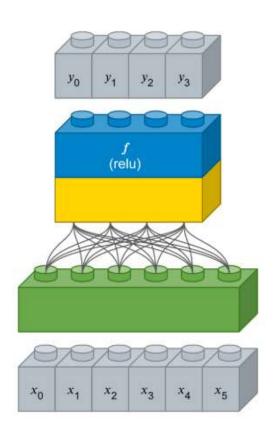




Dense(3, input_dim=4, activation='softmax')



Dense(4, input_dim=6, activation='relu'))



▶ 오차 함수

평균 제곱 계열	mean_squared_error	평균 제곱 오차			
		mean(square(yt - yo))			
	mean_absolute_error	평균 절대 오차(실제 값과 예측 값 차이의 절댓값 평균)			
		mean(abs(yt - yo))			
	mean_absolute_percentage_error	평균 절대 백분율 오차(절댓값 오차를 절댓값으로 나눈 후 평균)			
		mean(abs(yt - yo)/abs(yt) (단, 분모 ≠ 0)			
	mean_squared_logarithmic_error	평균 제곱 로그 오차(실제 값과 예측 값에 로그를 적용한 값의 차			
		이를 제곱한 값의 평균)			
		mean(square((log(yo) + 1) - (log(yt) + 1)))			
	categorical_crossentropy	범주형 교차 엔트로피(일반적인 분류)			
	binary_crossentropy	이항 교차 엔트로피(두 개의 클래스 중에서 예측할 때)			
용		예측 값이 참과 거짓 둘 중 하나인 형식일 때 사용			

▶ 피마 인디언 데이터 분석 실습

- 피마 인디언은 1950년대까지만 해도 비만인 사람이 단 한 명도 없는 민족이었습니다.
- 생존하기 위해 영양분을 체내에 저장하는 뛰어난 능력을 물려받은 인디언들이 미국의 기름진 패스트푸드 문화를 만나면서
- 지금은 전체 부족의 60%가 당뇨, 80%가 비만으로 고통받고 있습니다.

	١	속성					클래스
		정보 1	정보 2	정보 3		정보 8	당뇨병 여부
	1번째 인디언	6	148	72	215	50	1
샘플 ㅡ	2번째 인디언	1	85	66		31	0
	3번째 인디언	8	183	64	***	32	1

	768번째 인디언	1	93	70	***	23	0

샘플 수: 768

• 속성: 8

- 정보 1 (pregnant): 과거 임신 횟수

- 정보 2 (plasma): 포도당 부하 검사 2시간 후 공복 혈당 농도(mm Hq)

- 정보 3 (pressure): 확장기 혈압(mm Hg)

- 정보 4 (thickness): 삼두근 피부 주름 두께(mm)

- 정보 5 (insulin): 혈청 인슐린(2-hour, mu U/ml)

- 정보 6 (BMI): 체질량 지수(BMI, weight in kg/(height in m)²)

- 정보 7 (pedigree): 당뇨병 가족력

- 정보 8 (age): 나이

• 클래스: 당뇨(1), 당뇨 아님(0)

▶ 피마 인디언 데이터 분석 실습

```
from keras.models import Sequential
from keras.layers import Dense
import numpy
import tensorflow as tf
seed = 0
                                # seed 값 생성
numpy.random.seed(seed)
tf.set_random_seed(seed)
dataset = numpy.loadtxt("./dataset/pima-indians-diabetes.csv", delimiter=",") # 데이터 로드
X = dataset[:,0:8]
Y = dataset[:,8]
                                                   # 모델의 설정
model = Sequential()
model.add(Dense(12, input dim=8, activation='relu'))
model.add(Dense(8, activation='relu'))
model.add(Dense(1, activation='sigmoid'))
model.compile(loss='binary_crossentropy', optimizer='adam',
                                                             metrics=['accuracy']) # 모델 컴파일
                                                             # 모델 실행
model.fit(X, Y, epochs=200, batch size=10)
print("₩n Accuracy: %.4f" % (model.evaluate(X, Y)[1]))
                                                            # 결과 출력
```

▶ 다중 분류 분석 실습

■ 아이리스 데이터의 샘플, 속성, 클래스 구분

	ſ		클래스			
		정보 1	정보 2	정보 3	정보 4	품종
Γ	1번째 아이리스	5,1	3,5	4.0	0,2	Iris-setosa
	2번째 아이리스	4.9	3,0	1,4	0,2	Iris-setosa
샘플 ㅡ	3번째 아이리스	4.7	3,2	1,3	0.3	Iris-setosa
		***		147	***	
	150번째 아이리스	5.9	3.0	5.1	1,8	Iris-virginica

샘플 수: 150

- 속성 수: 4

- 정보 1: 꽃받침 길이 (sepal length, 단위: cm) 정보 2: 꽃받침 넓이 (sepal width, 단위: cm) 정보 3: 꽃잎 길이 (petal length, 단위: cm)
- 정보 4: 꽃잎 넓이 (petal width, 단위: cm)
- 클래스: Iris-setosa, Iris-versicolor, Iris-virginica

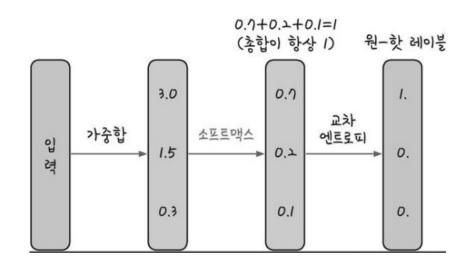
▶ 다중 분류 분석 실습

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
df = pd.read csv('../dataset/iris.csv', names = ["sepal length", "sepal width", "petal length", "petal width",
"species"])
print(df.head())
sns.pairplot(df, hue='species') #속성별 연관성 파악
plt.show()
dataset = df.values
X = dataset[:,0:4].astype(float)
Y obj = dataset[:,4]
from sklearn.preprocessing import LabelEncoder
e = LabelEncoder()
                      # array(['Iris-setosa', 'Iris-versicolor', 'Iris-virginica'])가 array([1,2,3])로 변환
e.fit(Y obj)
Y = e.transform(Y obj)
from keras.utils import np utils
# array([1,2,3])가 다시 array([[1., 0., 0.], [0., 1., 0.], [0., 0., 1.]])로 원-핫 인코딩(one-hot-encoding) 변환
Y encoded = np_utils.to_categorical(Y)
```

▶ 다중 분류 분석 실습

■ 소프트맥스(softmax) - 총합이 1인 형태로 바꿔서 계산해 주는 함수

<u>합계가 1인 형태로 변환하면 큰 값이 두드러지게 나타나고 작은 값은 더 작아집니다</u>. 이 값이 교차 엔트로피를 지나 [1., 0., 0.]으로 변화하게 되면 우리가 원하는 원-핫 인코딩 값, 즉 하나만 1이고 나머지는 모두 0인 형태로 전환시킬 수 있습니다.



▶ 다중 분류 분석 실습

```
from keras.models import Sequential
from keras.layers.core import Dense
import numpy
import tensorflow as tf
seed = 0
numpy.random.seed(seed) # seed 값 설정
tf.set random seed(seed)
model = Sequential() # 모델의 설정
model.add(Dense(16, input_dim=4, activation='relu'))
#최종 출력 값이 3개 중 하나여야 하므로 출력층에 해당하는 Dense의 노드 수를 3으로 설정
model.add(Dense(3, activation='softmax'))
# 모델 컴파일(다중 분류에 적절한 오차 함수인 categorical_crossentropy를 사용, 최적화 함수로 adam 사용)
model.compile(loss='categorical crossentropy', optimizer='adam', metrics=['accuracy'])
# 모델 실행(한 번에 입력되는 값은 1개, 전체 샘플이 50회 반복될 때까지 실험을 진행
model.fit(X, Y encoded, epochs=50, batch size=1)
print("₩n Accuracy: %.4f" % (model.evaluate(X, Y_encoded)[1])) # 결과 출력
```

▶ 초음파 광물 예측 분석 실습

	Range Index: 208 entries,0 to 207					
	Data columns (total 61 columns):					
0	208	non-null	float64			
1	208	non-null	float64			
2	208	non-null	float64			
3	208	non-null	float64			
4	208	non-null	float64			
5	208	non-null	float64			
58	208	non-null	float64			
59	208	non-null	float64			
60	208	non-null	object			
	Dtypes: float64(60), object(1)					
	memory usage: 99.2+ KB					

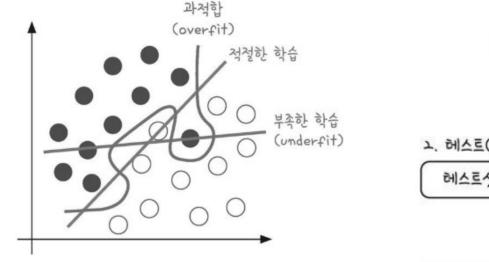
	0	1	2	3	 59	60
0	0.02	0.0371	0.0428	0.0207	 0.0032	R
1	0.0453	0.0523	0.0843	0.0689	 0.0044	R
2	0.0262	0.0582	0.1099	0.1083	 0.0078	R
3	0.01	0.0171	0.0623	0.0205	 0.0117	R
4	0.0762	0.0666	0.0481	0.0394	 0.0094	R

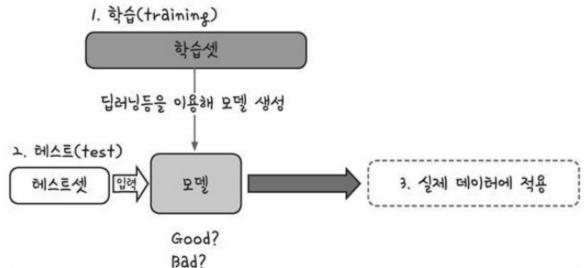
▶ 초음파 광물 예측 분석 실습

```
from keras.models import Sequential
from keras.layers.core import Dense
from sklearn.preprocessing import LabelEncoder
import pandas as pd
import numpy
import tensorflow as tf
seed = 0
numpy.random.seed(seed) # seed 값 설정
tf.set random seed(seed)
df = pd.read_csv('../dataset/sonar.csv', header=None) # 데이터 입력
dataset = df.values
X = dataset[:.0:60]
Y obj = dataset[:,60]
e = LabelEncoder()
e.fit(Y obi)
Y = e.transform(Y obj) # 문자열 변환
model = Sequential() # 모델 설정
model.add(Dense(24, input dim=60, activation='relu'))
model.add(Dense(10, activation='relu'))
model.add(Dense(1, activation='sigmoid'))
model.compile(loss='mean squared error', optimizer='adam', metrics=['accuracy']) # 모델 컴파일
                                       # 모델 실행
model.fit(X, Y, epochs=200, batch size=5)
print("₩n Accuracy: %.4f" % (model.evaluate(X, Y)[1])) # 결과 출력
```

▶ 과적합 피하기

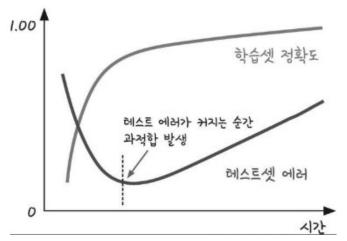
- 과적합(over fitting) 모델이 학습 데이터셋 안에서는 일정 수준 이상의 예측 정확도를 보이지만, 새로운 데이터에 적용하면 잘 맞지 않는 것
- 과적합은 층이 너무 많거나 변수가 복잡해서 발생하기도 하고 테스트셋과 학습셋이 중복될 때 생기기도 합니다
- 과적합을 방지 방법 학습을 하는 데이터셋과 이를 테스트할 데이터셋을 완전히 구분한 다음 학습과 동 시에 테스트를 병행하며 진행





▶ 과적합 피하기

- 머신러닝의 최종 목적 <u>과거의 데이터를 토대로 새로운 데이터를 예측하는 것</u> 새로운 데이터에 사용할 모델을 만드는 것
- 학습셋만 가지고 평가할때, 층을 더하거나 에포크(epoch) 값을 높여 실행 횟수를 늘리면 정확도가 계속해서 올라갈 수 있습니다.
- 학습 데이터셋만으로 평가한 예측 성공률이 테스트셋에서도 그대로 나타나지는 않습니다.
- 학습이 깊어져서 학습셋 내부에서의 성공률은 높아져도 테스트셋에서는 효과가 없다면 과적합이 일어나고 있는 것입니다.



학습이 계속되면 학습셋에서의 정확도는 계속 올라가지만, 테스트셋에서는 과적합이 발생!

온닉층 수의 변화	학습셋의 예측률	테스트셋의 예측률
0	79.3	73.1
2	96.2	85.7
3	98.1	87.6
6	99.4	89.3
12	99.8	90.4
24	100	89.2

▶ 초음파 광물 예측 분석(학습셋과 테스트셋 구분) 실습

```
from keras.models import Sequential
from keras.layers.core import Dense
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
import pandas as pd
import numpy
import tensorflow as tf
seed = 0
numpy.random.seed(seed) # seed 값 설정
tf.set random seed(seed)
df = pd.read_csv('../dataset/sonar.csv', header=None)
dataset = df.values
X = dataset[:,0:60]
Y_obj = dataset[:,60]
e = LabelEncoder()
e.fit(Y_obj)
Y = e.transform(Y obj)
```

▶ 초음파 광물 예측 분석(학습셋과 테스트셋 구분) 실습

```
# 학습셋과 테스트셋의 구분
X_train, X_test, Y_train, Y_test = train_testsplit(X, Y, test_size=0.3, random_state=seed)

model = Sequential()
model.add(Dense(24, input_dim=60, activation='relu'))
model.add(Dense(10, activation='relu'))
model.add(Dense(1, activation='sigmoid'))

model.compile(loss='mean_squared_error', optimizer='adam', metrics=['accuracy'])
model.fit(X_train, Y_train, epochs=130, batch_size=5)

# 테스트셋에 모델 적용
print("\underline" Test Accuracy: %.4f" % (model.evaluate(X_test, Y_test)[1]))
```

▶ 초음파 광물 예측 분석 - 모델 저장과 재사용

```
model = Sequential()
model.add(Dense(24, input_dim=60, activation='relu'))
model.add(Dense(10, activation='relu'))
model.add(Dense(1, activation='sigmoid'))

model.compile(loss='mean_squared_error', optimizer='adam', metrics=['accuracy'])

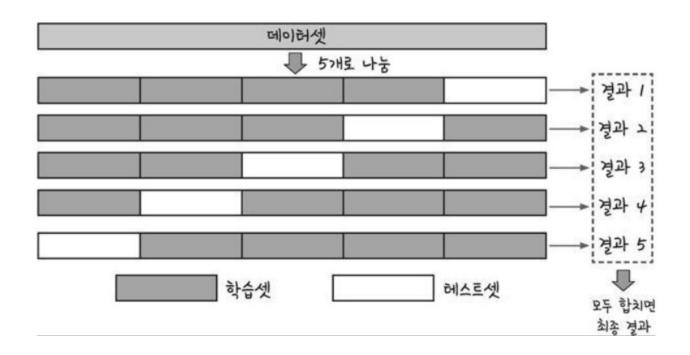
model.fit(X_train, Y_train, epochs=130, batch_size=5)
model.save('./output/my_model.h5') # 모델을 컴퓨터에 저장

del model # 테스트를 위해 메모리 내의 모델을 삭제
model = load_model('./output/my_model.h5') # 모델을 새로 불러옴

print("\n Test Accuracy: %.4f" % (model.evaluate(X_test, Y_test)[1])) # 불러온 모델로 테스트 실행
```

▶ k겹 교차 검증

- k겹 교차 검증(k-fold cross validation) k겹 교차 검증이란 데이터셋을 여러 개로 나누어 하나씩 테스트 셋으로 사용하고 나머지를 모두 합해서 학습셋으로 사용하는 방법
- 데이터가 충분치 않은 경우, 데이터의 100%를 테스트셋으로 사용할 수 있습니다.



▶ 초음파 광물 예측 분석 - k겹 교차 검증

```
# 10개의 파일로 쪼개 테스트하는 10-fold cross validation을 실시하도록 n fold의 값을 10으로 설정한
뒤 StratifiedKFold() 함수에 적용했습니다. 그런 다음 모델을 만들고 실행하는 부분을 for 구문으로 묶어 n fold만큼
반복되게 합니다.
from sklearn.model selection import StratifiedKFold
n fold = 10
skf = StratifiedKFold(n splits=nfold, shuffle=True, randomstate=seed)
accuracy = [] # 빈 accuracy 배열
for train, test in skf.split(X, Y): # 모델의 설정, 컴파일, 실행
  model = Sequential()
  model.add(Dense(24, input dim=60, activation='relu'))
  model.add(Dense(10, activation='relu'))
  model.add(Dense(1, activation='sigmoid'))
  model.compile(loss='mean_squared_error', optimizer='adam', metrics=['accuracy'])
  model.fit(X[train], Y[train], epochs=100, batch size=5)
  k_accuracy = "%.4f" % (model.evaluate(X[test], Y[test])[1])
  accuracy.append(k accuracy)
# 결과 춬력
print("₩n %.f fold accuracy:" % n_fold, accuracy)
```

와인의 종류 예측 분석

- 총 6497개의 샘플
- 13개의 속성

0	주석산 농도	7	밀도
1	아세트산 농도	8	рН
2	구연산 농도	9	황산칼륨 농도
3	잔류 당분 농도	10	알코올 도수
4	염화나트륨 농도	11	와인의 맛(0~10등급)
5	유리 아황산 농도	12	class (1: 레드와인, 0: 화이트와인)
6	총 아황산 농도		

▶ 와인의 종류 예측 분석

```
from keras.models import Sequential
from keras.layers import Dense
from keras.callbacks import ModelCheckpoint, EarlyStopping
import pandas as pd
import numpy
import tensorflow as tf
import matplotlib.pyplot as plt
seed = 0
numpy.random.seed(seed) # seed 값 설정
tf.set random seed(seed)
df pre = pd.read csv('../dataset/wine.csv', header=None)
df = df pre.sample(frac=1) #rac = 1 지정은 원본 데이터의 100%를 불러오라는 의미
dataset = df.values
X = dataset[:,0:12]
Y = dataset[:,12]
model = Sequential() # 모델 설정(4개의 은닉층을 만들어 각각 30, 12, 8, 1개의 노드를 주었습니다)
model.add(Dense(30, input dim=12, activation='relu'))
model.add(Dense(12, activation='relu'))
model.add(Dense(8, activation='relu'))
model.add(Dense(1, activation='sigmoid'))
```

▶ 와인의 종류 예측 분석

```
model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy']) # 모델 컴파일
model.fit(X, Y, epochs=200, batch_size=200) # 모델 실행
print("\n Accuracy: %.4f" % (model.evaluate(X, Y)[1])) # 결과 출력
```

와인의 종류 예측 분석 – 모델 업데이트

```
#에포크(epoch)마다 모델의 정확도를 함께 기록하면서 저장
from keras.callbacks import ModelCheckpoint
# 모델 컴파일
model.compile(loss='binary crossentropy', optimizer='adam', metrics=['accuracy'])
# 모델 저장 폴더 설정
MODEL DIR = './model/'
if not os.path.exists(MODEL DIR):
  os.mkdir(MODEL_DIR)
#테스트 오차는 케라스 내부에서 val loss, 학습 정확도는 acc, 테스트셋 정확도는 val acc, 학습셋 오차는 loss로 각
각 기록됩니다
# 모델 저장 조건 설정
modelpath="./model/{epoch:02d}-{val loss:.4f}.hdf5"
checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val loss', verbose=1, save best only=True)
# 모델 실행 및 저장
model.fit(X, Y, validation split=0.2, epochs=200, batch size=200, verbose=0, callbacks=[checkpointer])
```

▶ 와인의 종류 예측 분석 – 그래프 표현

```
import matplotlib.pyplot as plt
#sample() 함수를 이용하여 전체 샘플 중 15%만 불러오게 하고, 배치 크기는 500으로 늘려 한 번 딥러닝을 가동할
때 더 많이 입력되게끔 했습니다. 불러온 샘플 중 33%는 분리하여 테스트셋으로 사용하였습니다.
# 모델 실행 및 저장
history = model.fit(X, Y, validation split=0.33, epochs=3500, batch size=500)
# v vloss에 테스트셋(33%)으로 실험 결과의 오차 값을 저장
y_vloss=history.history['val_loss']
# y acc에 학습셋(67%)으로 측정한 정확도의 값을 저장
y acc=history.history['acc']
#x 값을 지정하고 정확도를 파란색으로, 오차를 빨간색으로 표시
x_len = numpy.arange(len(y_acc))
plt.plot(x len, y vloss, "o", c="red", markersize=3)
plt.plot(x_len, y_acc, "o", c="blue", markersize=3)
plt.show()
```

▶ 와인의 종류 예측 분석 – 학습의 자동 중단

▶ 선형 회귀 적용- 보스턴 집값 예측 분석

- 1978년, 집값에 가장 큰 영향을 미치는 것이 '깨끗한 공기'라는 연구 결과가 하버드대학교 도시개발학과에 서 발표
- 집값의 변동에 영향을 미치는 여러 가지 요인을 모아서 환경과 집값의 변동을 보여주는 데이터셋 머신러닝의 선형 회귀를 테스트하는 가장 유명한 데이터로 쓰이고 있음
- 수치를 예측하는 문제 (선형 회귀 문제)
- 머신러닝 혹은 딥러닝을 위해 주어진 데이터의 답을 구하는 문제 (여러 개 중에 정답을 맞히거나, 가격, 성적 같은 수치를 맞히는 것)
- 506 entries, 14 columns (13개의 속성과 1개의 클래스로 이루어졌음)

▶ 선형 회귀 적용- 보스턴 집값 예측 분석

컬럼(속성명)	설 명
CRIM	인구 1인당 범죄 발생 수
ZN	25,000평방 피트 이상의 주거 구역 비중
INDUS	소매업 외 상업이 차지하는 면적 비율
CHAS	찰스강 위치 변수(1: 강 주변, 0: 이외)
NOX	일산화질소 농도
RM	집의 평균 방 수
AGE	1940년 이전에 지어진 비율
DIS	5가지 보스턴 시 고용 시설까지의 거리
RAD	순환고속도로의 접근 용이성
TAX	\$10,000당 부동산 세율 총계
PTRATIO	지역별 학생과 교사 비율
В	지역별 흑인 비율
LSTAT	급여가 낮은 직업에 종사하는 인구 비율(%)
	가격(단위: \$1,000)

- ▶ 선형 회귀 적용- 보스턴 집값 예측 분석
 - 선형 회귀 데이터는 마지막에 참과 거짓을 구분할 필요가 없기 때문에 출력층에 활성화 함수를 지정할 필요도 없습니다.
 - 모델의 학습이 어느 정도 되었는지 확인하기 위해 예측 값과 실제 값을 비교하는 부분을 추가합니다.

```
from keras.models import Sequential
from keras.layers import Dense
from sklearn.model_selection import train_test_split
import numpy
import pandas as pd
import tensorflow as tf

seed = 0
numpy.random.seed(seed) # seed 값 설정
tf.set_random_seed(seed)

df = pd.read_csv(".../dataset/housing.csv", delim_whitespace=True, header=None)
dataset = df.values
X = dataset[:,0:13]
Y = dataset[:,13]
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.3, random_state=seed)
```

선형 회귀 적용- 보스턴 집값 예측 분석



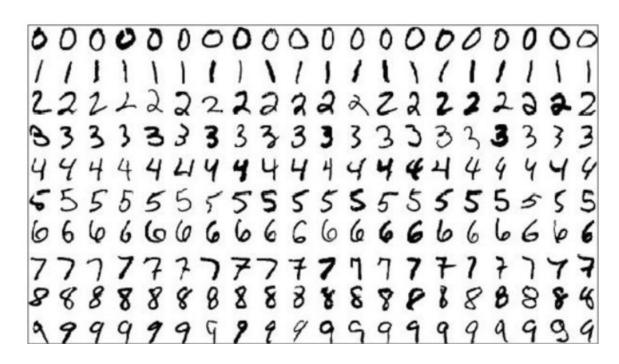
```
model = Sequential()
model.add(Dense(30, input_dim=13, activation='relu'))
model.add(Dense(6, activation='relu'))
model.add(Dense(1))

model.compile(loss='mean_squared_error', optimizer='adam')
model.fit(X_train, Y_train, epochs=200, batch_size=10)

#flatten() - 데이터 배열이 몇 차원이든 모두 1차원으로 바꿔 읽기 쉽게 해 주는 함수
Y_prediction = model.predict(X_test).flatten() # 예측 값과 실제 값의 비교
for i in range(10):
    label = Y_test[i]
    prediction = Y_prediction[i]
    print("실제가격: {:.3f}, 예상가격: {:.3f}".format(label, prediction))
```

▶ MNIST 손글씨 인식하기

- MNIST 데이터셋은 미국 국립표준기술원(NIST)이 고등학생과 인구조사국 직원 등이 쓴 손글씨를 이용해 만든 데이터로 구성
- 70,000개의 글자 이미지에 각각 0부터 9까지 이름표를 붙인 데이터셋
- 딥러닝을 이용해 과연 이 손글씨 이미지를 몇 %나 정확히 예측할 수 있을까요?



- 이미지 데이터를 X
- 이미지에 0~9까지 붙인 이름표를 Y class
- 70,000개의 이미지 중 60,000개를 학습용, 10,000개를 테스트용으로 구분

➤ MNIST 손글씨 인식하기

- 이미지는 가로 28 × 세로 28 = 총 784개의 픽셀로 이루어져 있습니다.
- 각 픽셀은 밝기 정도에 따라 0부터 255까지의 등급을 매깁니다.
- 흰색 배경이 0이라면 글씨가 들어간 곳은 1~255까지 숫자 중 하나로 채워져 긴 행렬로 이루어진 하나의 집합으로 변환됩니다.

for x in X_train[0]:
 for i in x:
 sys.stdout.write('%d₩t' % i)
 sys.stdout.write('₩n')

- MNIST 손글씨 인식하기: 데이터 전처리
 - 28 × 28 = 784개의 속성을 이용해 0~9까지 10개 클래스 중 하나를 맞히는 분류 문제가 됩니다.
 - Reshape() 함수를 사용하여 가로 28, 세로 28의 2차원 배열을 784개의 1차원 배열로 바꿔 주어야 합니다.
 - 케라스는 데이터를 0에서 1 사이의 값으로 변환해야 구동할 때 최적의 성능을 보이므로 0~255 사이의 값으로 이루어진 값을 0~1 사이의 값으로 값을 255로 나누어 데이터 정규화(normalization) 합니다.
 - Y_class를 np_utils.to_categorical(클래스, 클래스의 개수)를 사용하여 원-핫 인코딩 합니다.

```
from keras.datasets import mnist
from keras.utils import np_utils
import numpy
import sys
import tensorflow as tf

seed = 0
numpy.random.seed(seed) # seed 값 설정
tf.set_random_seed(seed)

# MNIST 데이터셋 불러오기
(X_train, Y_class_train), (X_test, Y_class_test) = mnist.load_data()
print("학습셋 이미지 수: %d 개" % (X_train.shape[0]))
print("테스트셋 이미지 수: %d 개" % (X_test.shape[0]))
```

▶ MNIST 손글씨 인식하기: 데이터 전처리

```
# 그래프로 확인
import matplotlib.pyplot as plt
plt.imshow(X train[0], cmap='Greys')
plt.show()
                             # 코드로 확인
for x in X_train[0]:
  for i in x:
     sys.stdout.write('%d\t' % i)
   sys.stdout.write('₩n')
# 차원 변환 과정
X_train = X_train.reshape(X_train.shape[0], 784)
X_train = X_train.astype('float64')
X_train = X_train / 255
X_test = X_test.reshape(X_test.shape[0], 784).astype('float64') /255
print("class: %d " % (Y_class_train[0])) # 클래스 값 확인
# 바이너리화 과정
Y_train = np_utils.to_categorical(Y_class_train, 10)
Y test = np utils.to categorical(Y class test, 10)
print(Y train[0])
```

- ➤ MNIST 손글씨 인식하기: 딥러닝 실행
 - 딥러닝을 실행하고자 프레임을 설정(총 784개의 속성, 10개의 클래스)
 - 입력 값(input_dim)이 784개, 은닉층이 512개 , 출력이 10개인 모델
 - 활성화 함수로 은닉층에서는 relu를, 출력층에서는 softmax를 사용합니다
 - 모델의 실행에 앞서 모델의 성과를 저장하고 모델의 최적화 단계에서 학습을 자동 중단하게끔 설정합니다.
 - 샘플 200개를 모두 30번 실행하게끔 설정합니다.
 - 테스트셋으로 최종 모델의 성과를 측정하여 그 값을 출력합니다.
 - 학습셋의 정확도 대신 학습셋의 오차를 그래프로 표현해봅니다
 - 학습셋의 오차는 1에서 학습셋의 정확도를 뺀 값입니다.

```
from keras.models import Sequential
from keras.layers import Dense
from keras.callbacks import ModelCheckpoint,EarlyStopping
import matplotlib.pyplot as plt
Import os

# 모델 프레임 설정
model = Sequential()
model.add(Dense(512, input_dim=784, activation='relu'))
model.add(Dense(10, activation='softmax'))
```

▶ MNIST 손글씨 인식하기: 딥러닝 실행

```
# 모델 실행 환경 설정
model.compile(loss='categorical crossentropy', optimizer='adam', metrics=['accuracy'])
# 모델 최적화 설정
MODEL DIR = './model/'
if not os.path.exists(MODEL DIR):
  os.mkdir(MODEL DIR)
modelpath="./model/{epoch:02d}-{valloss:.4f}.hdf5"
checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val loss', verbose=1, save best only=True)
early stopping callback = EarlyStopping(monitor='val loss', patience=10)
# 모델의 실행
history = model.fit(X_train, Y_train, validation_data=(X_test, Y_test), epochs=30, batch size=200, verbose=0,
callbacks=[earlystopping callback,checkpointer])
# 테스트 정확도 출력
print("\u21ammn Test Accuracy: \u21amma.4f" \u21amm (model.evaluate(X test, Y test)[1]))
# 테스트셋의 오차
y_vloss = history.history['val_loss']
```

➤ MNIST 손글씨 인식하기: 딥러닝 실행

```
# 학습셋의 오차
y loss = history.history['loss']
# 그래프로 표현
x_len = numpy.arange(len(y_loss))
plt.plot(x_len, y_vloss, marker='.', c="red", label='Testset loss')
plt.plot(x_len, y_loss, marker='.', c="blue", label='Trainset loss')
# 그래프에 그리드를 주고 레이블을 표시
plt.legend(loc='upper right')
# plt.axis([0, 20, 0, 0.35])
plt.grid()
plt.xlabel('epoch')
plt.ylabel('loss')
plt.show()
                                                       (베스트 모델 시 중단)
                                                                         오차 항수
                                                            아당
                      X,...X
                                                                           소포트
                                                   렌루
                                                                           맥스
                                                              (10개의 출력)
                   (184개의 속성)
                                     (51고개의 노드)
```

- ➤ 컨볼루션 신경망(Convolutional Neural Network, CNN)
 - 기본 딥러닝 프레임에 이미지 인식 분야에서 강력한 성능을 보이는 신경망
 - 입력된 이미지에서 다시 한번 특징을 추출하기 위해 마스크(필터, 윈도 또는 커널이라고도 함)를 도입하는 기법
 - 입력층과 출력층 사이의 중간층(은폐층)에 합성곱과 풀링층을 배치한 것
 - 이미지를 흐리게 만들거나 경계를 강조하는 작업을 함
 - 합성곱층과 풀링층에서는 해상도를 낮추거나 샘플링하는 처리를 계속 반복함

1	0	1	0
0	1	1	0
0	0	1	1
0	0	1	0

×/	×O
×O	×I

2×2 마스크 (가중치)

l×l	0×0	1	0
0×0	l×l	1	0
0	0	1	1
0	0	1	0

 $(1 \times 1) + (0 \times 0) + (0 \times 0) + (1 \times 1) = 2$

입력된 이미지

마스크 (가중치) 적용 새로운 값 추출

➤ 컨볼루션 신경망(Convolutional Neural Network, CNN)

I×I	0×0	1	0	1	0×1	I×O	0	1	0	I×I	0×0
0×0	I×I	1	0	0	IXO	1×1	0	0	1	IXO	0×I
0	0	1	ı	0	0	1	1	0	0	1	1
0	0	1	0	0	0	1	0	0	0	1	0

1	0	1	0	1	0	1	0	1	0	1	0
0×I	I×0	1	0	0	1×1	1×0	0	0	1	IXI	0×0
0×0	0×I	ı	1	0	0×0	l×l	1	0	0	IXO	l×l
0	0	1	0	0	0	1	0	0	0	1	0

1	0	1	0	1	0	1	0	1	0	1	0
0	1	1	0	0	1	1	0	0	1	1	0
0×I	0×0	1	1	0	0×1	I×O	1	0	0	I×I	IXO
0×0	0×1	1	0	0	0×0	I×I	0	0	0	I×O	0×I

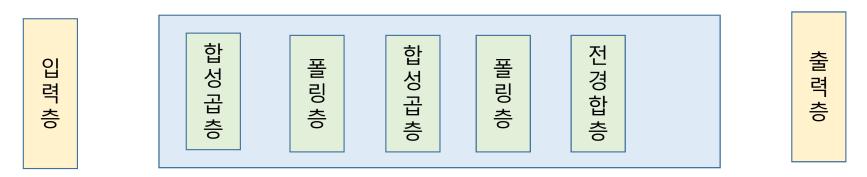
마스크를 한 칸씩 옮겨 모두 적용 결과

7	1	1
0	ı	ı
0	1	1

합성곱층 이미지의 특징을 추출할 때 사용

▶ 컨볼루션 신경망(Convolutional Neural Network, CNN)

- 합성곱층은 이미지의 특징을 추출할 때 사용
- 입력 x의 일부분을 잘라내고, 가중치 필터 W를 적용해 특징 맵 c를 만들어 낼 때 사용
- 입력 x의 일부분을 조금씩 자르면서 평활화와 윤곽선 검출 처리를 하며, 특징 맵 c를 추출
- 합성곱층의 역할은 주변의 값과 필터를 사용해 중앙에 있는 값을 변화시키는 것
- 평활화(Equalization) 명암의 분포가 균일하지 못한 이미지에 적용해 분포를 균일하게 만들어주는 것

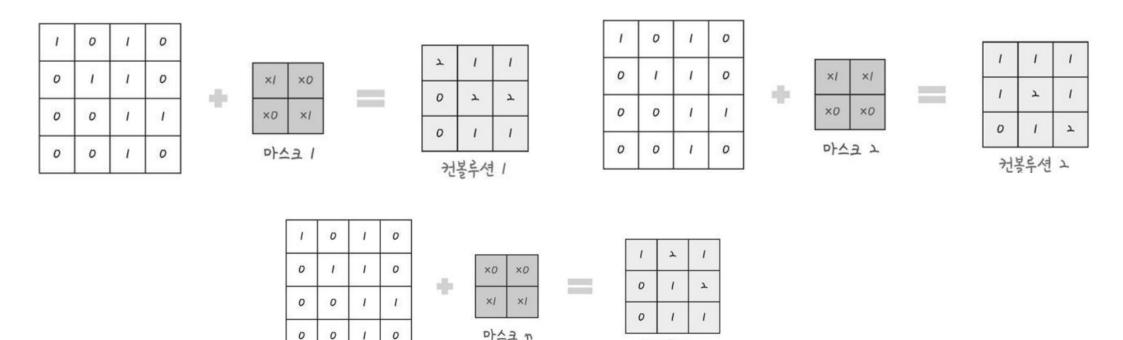


중간층

- 풀링층은 합성곱층으로 얻은 특징맵 c를 축소하는 층 max pooling, average pooling
- 전결합층은 각 층의 유닛을 결합

- ▶ 컨볼루션 신경망(Convolutional Neural Network, CNN)
 - 새롭게 만들어진 층을 컨볼루션(합성곱)이라고 부릅니다.
 - 마스크를 여러 개 만들 경우 여러 개의 컨볼루션이 만들어집니다.

0



컨봉루션 n

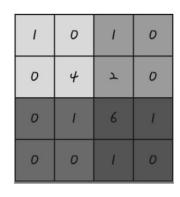
- ▶ 컨볼루션 신경망(Convolutional Neural Network, CNN)
 - 케라스에서 컨볼루션 층을 추가하는 함수는 Conv2D()입니다.

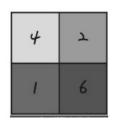
model.add(Conv2D(32, kernel_size=(3, 3), input_shape=(28, 28, 1), activation='relu'))

- 첫 번째 인자: 마스크를 몇 개 적용할지 정합니다
- kernel_size: 마스크(커널)의 크기를 정합니다. kernel_size=(행, 열) 형식으로 정합니다
- input_shape: Dense 층과 마찬가지로 맨 처음 층에는 입력되는 값을 알려주어야 합니다.
- activation: 활성화 함수를 정의합니다. (베스트 모델 시 중단) 오차 함수 Y convolution ha Y convolution h X,...X 소포르 렞루 엑루 렞루 맥스 (10개의 출력) (31개의 핑터, 3×3) (64개의 핑터, 3×3) (511개의 노드) (184개의 송성)

- ▶ 컨볼루션 신경망(Convolutional Neural Network, CNN) 맥스 풀링(max pooling)
 - 컨볼루션 층을 통해 이미지 특징을 도출 결과가 여전히 크고 복잡하면 다시 한번 축소해야 합니다.
 - 다시 한번 축소하는 과정을 풀링(pooling) 또는 서브 샘플링(sub sampling)이라고 합니다.
 - 맥스 풀링은 정해진 구역 안에서 가장 큰 값만 다음 층으로 넘기고 나머지는 버립니다.
 - MaxPooling2D()

1	0	1	0
0	4	7	0
0	I	6	I
0	0	ı	0

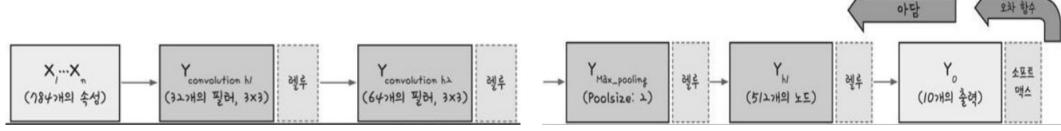




각 구역에서 가장 큰 값을 추출합니다

이미지

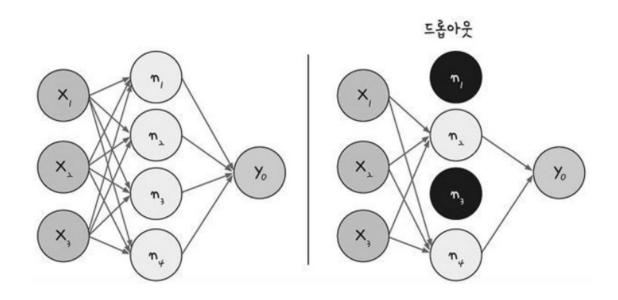
구역을 나눕니다.



오차 항수

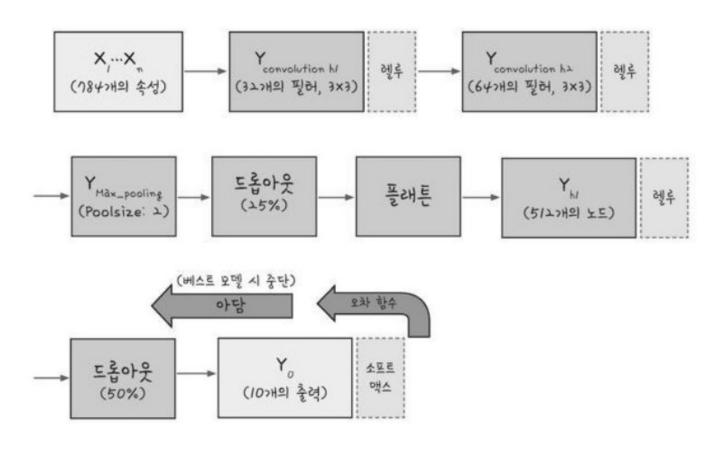
(베스트 모델 시 중단)

- ▶ 컨볼루션 신경망(Convolutional Neural Network, CNN) 과적합 피하기
 - 딥러닝 학습을 실행할 때 가장 중요한 것은 과적합을 얼마나 효과적으로 피해가는지에 달려 있습니다.
 - 드롭아웃(drop out) 기법 은닉층에 배치된 노드 중 일부를 임의로 꺼주는 것입니다.
 - 랜덤하게 노드를 끔으로써 학습 데이터에 지나치게 치우쳐서 학습되는 과적합을 방지할 수 있습니다.



model.add(Dropout(0.25)) #25%의 노드를 끔

▶ 컨볼루션 신경망(Convolutional Neural Network, CNN) – 과적합 피하기



드롭아웃과 플래튼 추가하기

```
from keras.datasets import mnist
from keras.utils import np_utils
from keras.models import Sequential
from keras.layers import Dense, Dropout, Flatten, Conv2D, MaxPooling2D
from keras.callbacks import ModelCheckpoint, EarlyStopping
import matplotlib.pyplot as plt
import numpy
import os
import tensorflow as tf
# seed 값 설정
seed = 0
numpy.random.seed(seed)
tf.set random seed(seed)
# 데이터 불러오기
(X train, Y train), (X test, Y test) = mnist.load data()
X_train = X_train.reshape(X_train.shape[0], 28, 28,1).astype('float32') / 255
X_{\text{test}} = X_{\text{test.reshape}}(X_{\text{test.shape}}[0], 28, 28, 1).astype('float32') / 255
Y train = np utils.to categorical(Y train)
Y test = np utils.to categorical(Y test)
```

```
# 컨볼루션 신경망 설정
model = Sequential()
model.add(Conv2D(32, kernel_size=(3, 3), input_shape=(28, 28, 1),activation='relu'))
model.add(Conv2D(64, (3, 3), activation='relu'))
model.add(MaxPooling2D(pool_size=2))
model.add(Dropout(0.25))
model.add(Flatten())
model.add(Dense(128, activation='relu'))
model.add(Dropout(0.5))
model.add(Dense(10, activation='softmax'))
model.compile(loss='categorical crossentropy', optimizer='adam', metrics=['accuracy'])
# 모델 최적화 설정
MODEL DIR = './model/'
if not os.path.exists(MODEL DIR):
  os.mkdir(MODEL_DIR)
modelpath="./model/{epoch:02d}-{val loss:.4f}.hdf5"
checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val_loss', verbose=1, save_best_only=True)
early stopping callback = EarlyStopping(monitor='val loss',patience=10)
```

```
# 모델의 실행
history = model.fit(X_train, Y_train, validation_data=(X_test, Y_test), epochs=30, batch_size=200, verbose=0,
callbacks=[early_
stopping callback,checkpointer])
# 테스트 정확도 출력
print("₩n Test Accuracy: %.4f" % (model.evaluate(X_test, Y_test)[1]))
# 테스트셋의 오차
y_vloss = history.history['val_loss']
# 학습셋의 오차
y_loss = history.history['loss']
# 그래프로 표현
x_len = numpy.arange(len(y_loss))
plt.plot(x_len, y_vloss, marker='.', c="red", label='Testset_loss')
plt.plot(x_len, y_loss, marker='.', c="blue", label='Trainset_loss')
```

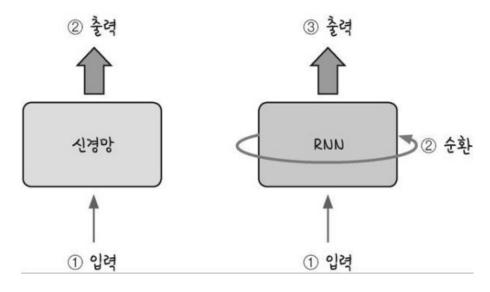
```
# 그래프에 그리드를 주고 레이블을 표시
plt.legend(loc='upper right')
plt.grid()
plt.xlabel('epoch')
plt.ylabel('loss')
plt.show()
```

- 각 층에서 뉴런(neuron)의 개수에는 제약이 없다.
- summary() 함수로 자신이 생성한 모델의 레이어, 출력 모양, 파라미터 개수 등을 체크할 수 있다.
- model.summary()
- 레이어의 설정 및 레이어의 층 구조에 따라서 모델의 성능이 달라지는 데, 변경해볼 수 있는 요소를 하이퍼 파라미터라고 하고, 이를 하이퍼파라미터 튜닝이라고 합니다.
- 마지막 출력층은 하이퍼파라미터가 없습니다.
- fit() 함수 로그에는 기본적으로 손실값과 정확도가 표시됩니다. 이진분류 모델에서는 정확도값 하나만 보더라도 학습이 제대로 되고 있는 지 알 수 있지만, 다중클래스분류 문제에서는 클래스별로 학습이 제대로 되고 있는 지 확인하기 위해서는 정확도값 하나로는 부족함이 많습니다.
- 메트릭은 평가 기준을 말합니다. compile() 함수의 metrics 인자로 여러 개의 평가 기준을 지정할 수 있습니다. 이러한 평가 기준에는 모델의 학습에는 영향을 미치지 않지만, 학습 과정 중에 제대로 학습되고 있는 지살펴볼 수 있습니다.
- 케라스에서는 다중클래스분류 문제에서 평가기준을 'accuracy'로 지정했을 경우 내부적으로 categorical_accuracy() 함수를 이용하여 정확도가 계산됩니다.

 evaluate() 함수는 손실값 및 메트릭 값을 반환하는 데, 여러 메트릭을 정의 및 등록하였으므로, 여러 개의 메트릭 값을 얻을 수 있습니다.

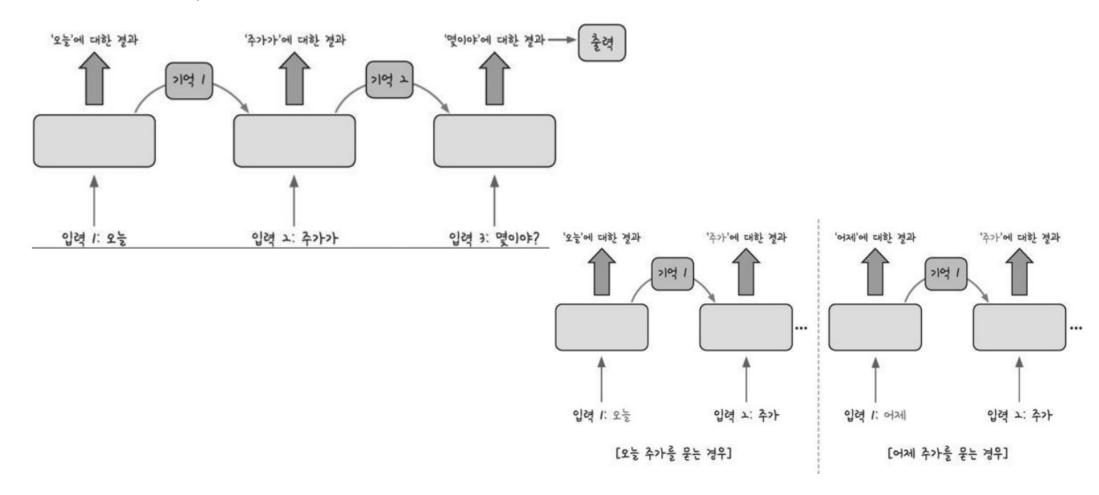
- 컨볼루션 레이어인 Conv2D에서는 필터의 수 "32"와 필터의 사이즈 "(3,3)"가 성능에 영향을 미칩니다
- Dense 레이어의 출력 뉴런 수인 "20"과 Dropout 레이어의 드랍비율인 "0.2"가 하이퍼파라미터가 됩니다
- 은닉층을 여러 번 쌓을 수도 있기에 몇 번 반복하느냐도 모델 구성에도 중요합니다.

- 대화형 인공지능 문장을 듣고 무엇을 의미하는지를 알아야 서비스를 제공
- 문장 학습 여러 개의 단어로 이루어진 문장의 각 단어가 정해진 순서대로 입력되어야 의미를 전달 할 수 있으므로 입력된 데이터 사이의 관계를 고려해야 합니다.
- 순환 신경망(Recurrent Neural Network, RNN)은 여러 개의 데이터가 순서대로 입력되었을 때 앞서 입력받은 데이터를 잠시 기억해 놓는 방법입니다.
- 모든 입력 값에 기억된 데이터가 얼마나 중요한지를 판단하여 별도의 가중치를 줘서 다음 층으로 데이터로 넘어갑니다.

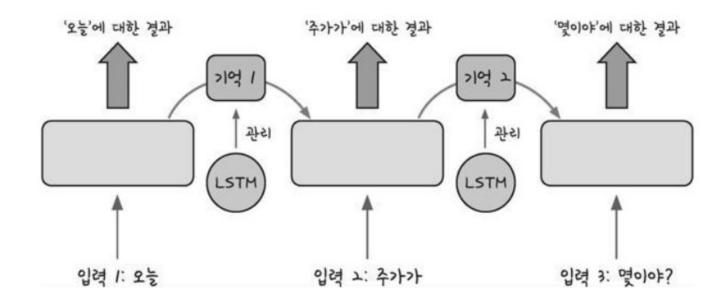


일반 신경망과 순환 신경망의 차이

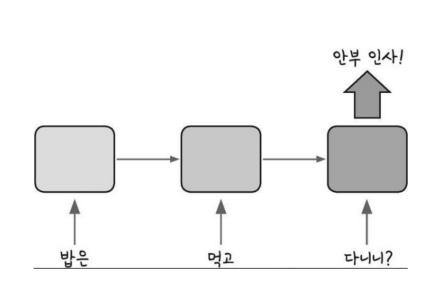
• 순환이 되는 가운데 앞서 나온 입력에 대한 결과가 뒤에 나오는 입력 값에 영향을 주는 것을 알 수 있습니다. 이렇게 해야지만, 비슷한 두 문장이 입력되었을 때 그 차이를 구별하여 출력 값에 반영할 수가 있습니다.



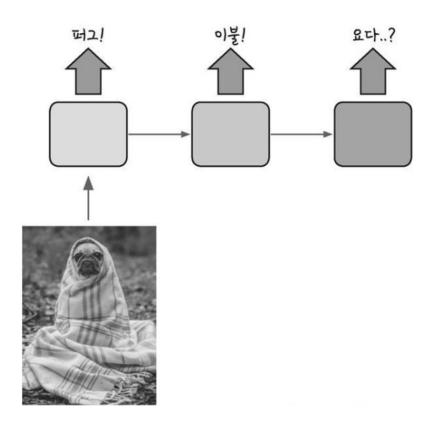
- LSTM(Long Short Term Memory) : 한 층 안에서 반복을 많이 해야 하는 RNN의 특성상 일반 신경망보다 기울기 소질 문제가 더 많이 발생하고 이를 해결하기 어렵다는 단점을 보완한 방법입니다.
- LSTM(Long Short Term Memory)은 반복되기 직전에 다음 층으로 기억된 값을 넘길지 안 넘길지를 관리하는 단계를 하나 더 추가하는 것입니다



• RNN 방식의 장점은 입력 값과 출력 값을 어떻게 설정하느냐에 따라 여러 가지 상황에서 이를 적용할 수 있다는 것입니다.

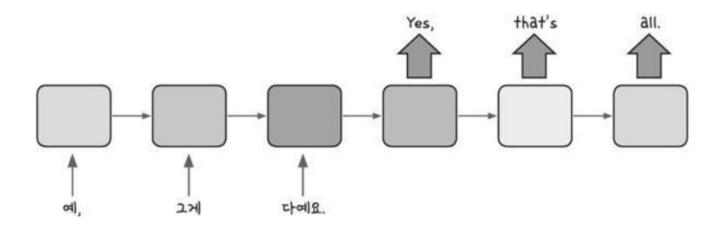


다수 입력 단일 출력(문장을 읽고 뜻을 파악할 때 활용)



단일 입력 다수 출력(사진의 캡션을 만들 때 활용)

• RNN 방식의 장점은 입력 값과 출력 값을 어떻게 설정하느냐에 따라 여러 가지 상황에서 이를 적용할 수 있다는 것입니다.



다수 입력 다수 출력(문장을 번역할 때 활용)

- ▶ LSTM을 이용한 로이터 뉴스 카테고리 분류
 - 입력된 문장의 의미를 파악하는 것은 곧 모든 단어를 종합하여 하나의 카테고리로 분류하는 작업이라고 할 수 있습니다.

증부 지방은 대체로 맑겠으나, 남부 지방은 구름이 많겠습니다. → 날씨을 초부터 유동성의 힘으로 주가가 일정하게 상승했습니다. → 주식이번 선거에서는 누가 이길 것 같아? → 정치 퍼셉트론의 한계를 극복한 신경망이 다시 뜨고 있대. → 딥러닝

- 로이터 뉴스 데이터 : 총 11,258개의 뉴스 기사가 46개의 카테고리로 나누어진 대용량 텍스트 데이터
- 딥러닝은 단어를 그대로 사용하지 않고 숫자로 변환한 다음 학습할 수 있습니다.
- 데이터 안에서 단어별 빈도에 따라 순서 번호를 붙였습니다.
- Embedding('불러온 단어의 총 개수', '기사당 단어 수') 층은 데이터 전처리 과정을 통해 입력된 값을 받아 다음 층이 알아들을 수 있는 형태로 변환하는 역할을 합니다.
- Embedding은 모델 설정 부분의 맨 처음에 있어야 합니다.
- LSTM(기사당 단어 수, 기타 옵션)은 RNN에서 기억 값에 대한 가중치를 제어합니다.
- LSTM의 활성화 함수로는 Tanh를 사용합니다.

▶ LSTM을 이용한 로이터 뉴스 카테고리 분류

```
from keras.datasets import reuters
from keras.models import Sequential
from keras.layers import Dense, LSTM, Embedding
from keras.preprocessing import sequence
from keras.utils import np utils
import numpy
import tensorflow as tf
import matplotlib.pyplot as plt
seed = 0 # seed 값 설정
numpy.random.seed(seed)
tf.set random seed(seed)
# 불러온 데이터를 학습셋과 테스트셋으로 나누기
(X train, Y train), (X test, Y test) = reuters.load data(num words=1000, test split=0.2)
# 데이터 확인하기
category = numpy.max(Y train) + 1
print(category, '카테고리')
print(len(X_train), '학습용 뉴스 기사')
print(len(X_test), '테스트용 뉴스 기사')
print(X train[0])
```

➤ LSTM을 이용한 로이터 뉴스 카테고리 분류

```
# 데이터 전처리
x_train = sequence.pad_sequences(X_train, maxlen=100)
x test = sequence.pad sequences(X test, maxlen=100)
y train = np utils.to categorical(Y train)
y test = np utils.to categorical(Y test)
model = Sequential() # 모델의 설정
model.add(Embedding(1000, 100))
model.add(LSTM(100, activation='tanh'))
model.add(Dense(46, activation='softmax'))
# 모델의 컴파일
model.compile(loss='categorical crossentropy',
                                               optimizer='adam',
                                                                       metrics=['accuracy'])
# 모델의 실행
history = model.fit(x train, y train, batch size=100, epochs=20, validation data=(x test, y test))
# 테스트 정확도 출력
print("₩n Test Accuracy: %.4f" % (model.evaluate(x_test, y_test)[1]))
```

▶ LSTM을 이용한 로이터 뉴스 카테고리 분류

```
# 테스트셋의 오차
y_vloss = history.history['val_loss']
# 학습셋의 오차
y loss = history.history['loss']
# 그래프로 표현
x_len = numpy.arange(len(y_loss))
plt.plot(x len, y vloss, marker='.', c="red", label='Testset loss')
plt.plot(x len, y loss, marker='.', c="blue", label='Trainset loss')
# 그래프에 그리드를 주고 레이블을 표시
plt.legend(loc='upper right')
plt.grid()
plt.xlabel('epoch')
plt.ylabel('loss')
plt.show()
```

- ➤ LSTM과 CNN의 조합을 이용한 영화 리뷰 분류
 - 인터넷 영화 데이터베이스(Internet Movie Database, IMDB)는 영화와 관련된 정보와 출연진 정보, 개봉 정보, 영화후기, 평점에 이르기까지 매우 폭넓은 데이터가 저장된 자료입니다.
 - 영화에 관해 남긴 2만 5000여 개의 영화 리뷰가 담겨 있으며, 해당 영화를 긍정적으로 평가했는지 혹은 부정적으로 평가했는지도 담겨 있습니다.

